Analisi comparativa di reti LSTM per la previsione multivariata nel mercato energetico del Centro-Sud Italia

Laureando
Francesco Saverio Saccucci

Relatore
Massimo Panella

Analisi comparativa di reti LSTM per la previsione multivariata nel mercato energetico del Centro-Sud Italia

Facoltà di Ingegneria dell'informazione, informatica e statistica
Dipartimento di INGEGNERIA INFORMATICA, AUTOMATICA E GESTIONALE "ANTONIO RUBERTI
Corso di laurea in Ingegneria Gestionale

Francesco Saverio Saccucci

Matricola 1883927

Relatore

Massimo Panella

Correlatore

Antonello Rosato

A.A. 2024-2025

ABSTRACT

Nell'ultimo ventennio il mercato dell'energia elettrica sta attraversando una fase di profonda trasformazione, guidata dalla transizione energetica e dalla crescente penetrazione delle fonti energetiche non programmabili. Questo scenario ha di fatto modificato la variabilità del prezzo nazionale e dei prezzi zonali, rendendo le previsioni tradizionali inadeguate per garantire previsioni di prezzo accurate. Il presente lavoro di tesi si pone l'obiettivo di sviluppare e confrontare modelli avanzati per il forecasting del prezzo dell'energia elettrica nella zona del Centro-Sud Italia. In particolare, sono state implementate diverse architetture basate su Long Short-Term Memory (LSTM) valutandone le performance su finestre di previsione orarie e giornaliere. L' analisi sperimentale ha evidenziato una dicotomia nelle performance a seconda dell'orizzonte di osservazione, in particolare le architetture puramente ricorrenti come LSTM e BI-LSTM, risultano superiori nella previsione oraria, mentre l'approccio ibrido CNN-LSTM ha mostrato performance migliori nella previsione giornaliera, beneficiando della convoluzione per estrarre feature significative dai dati. Tuttavia, sono emerse alcune criticità legate al periodo primaverile, dove uno squilibrio tra domanda e offerta ha prodotto prezzi prossimi allo zero con la conseguente generazione di previsioni poco accurate per i modelli. I risultati suggeriscono che per gestire questa volatilità estrema sia necessario evolvere l'analisi, integrando variabili esogene come previsioni meteorologiche, in grado di intercettare possibili cambiamenti di regime del mercato prima che si verifichino.

Sommario

Capitolo 1 – Introduzione e contesto del sistema elettrico 10
1.1 La previsione dei prezzi elettrici Day-Ahead 10
1.2 Obbiettivi e Definizione del problema 12
1.3 Il sistema elettrico nazionale 13
1.3.1 Il mix produttivo italiano 15
1.4 Struttura del mercato elettrico 17
1.4.1 Il Mercato del Giorno Prima (MGP) 20
1.4.2 Il Mercato Infragiornaliero (MI) 23
Capitolo 2 – Stato dell' arte e fondamenti teorici 25
2.1 La letteratura scientifica 25
2.2 Fondamenti di reti neurali 28
2.3 L' Architettura LSTM 30
2.3.1. Forget Gate 31
2.3.2. Input Gate 32
2.3.3. Output Gate 34
2.4 Architetture ibride 35
2.4.1 Reti LSTM Bidirezionali (BiLSTM) 35
2.4.2 Modelli Ibridi CNN-LSTM 36
2.4.3 Il Meccanismo di Attenzione 39
Capitolo 3 – Metodologia e set-up sperimentale 41
3.1 Metodologia 41
3.1.1 Strategia di partizionamento del dataset 41
3.1.2 Strategia di ottimizzazione degli iperparametri 42
3.1.3 Strategia di validazione 43
3.1.4 Contributo metodologico 44
3.2 Descrizione del dataset e analisi esplorativa 44

3.2.1 Andamento nel tempo 46
3.2.2 Scatter plot 49
3.2.3 Box plot 52
3.2.4 Mappa di Densità 53
3.3 Preprocessing dei dati 58
3.3.1 Divisione Cronologica del Dataset 58
3.3.2 Protocollo di Addestramento Dinamico 59
3.3.2 Normalizzazione 60
3.3.3 Creazione delle sequenze 61
3.4 Architetture dei modelli analizzati 63
3.5 Metriche di Valutazione 66
3.5.1 MAE 66
3.5.2 RMSE 66
3.5.3 MAPE 67
3.6 Strumenti e ambiente di sviluppo 67
3.6.1 Gestione e Manipolazione dei Dati 68
3.6.2 Normalizzazione e Metriche 68
3.6.3 Implementazione delle Architetture 68
3.6.4 Visualizzazione e Analisi dei Risultati 69
Capitolo 4 – Risultati e analisi comparativa 70
4.1 Training e ottimizzazione dei modelli 70
4.1.1 Tuning degli iperparametri 70
4.1.2 Dimensionalità delle architetture 71
4.1.3 Curve di training 72
4.2 Performance sul test-set 79
4.2.1 Metriche della previsione oraria 80
4.2.2 Metriche della previsione giornaliera. 82
4.3 Analisi grafica delle previsioni 84

4.3.2 Andamento delle previsioni giornaliere 87
Capitolo 5 – Conclusione e discussione critica dei risultati 90
5.1 Robustezza delle Metriche 90
5.2 Analisi dei modelli vincenti 91
5.3 Efficacia Architetturale 93
5.4 Differenze stagionali e impatto delle variabili esogene 94
5.5 Prospettive Future 96
Riferimenti Normativi e Regolatori 97
SITOGRAFIA 97
BIBLIOGRAFIA 98

Indice delle figure

Figura 1 Sistema elettrico italiano 13
Figura 2 Produzione netta per fonte e regione nell' anno 2024 16
Figura 3 Mappa delle zone geografiche del mercato elettrico nazionale [9]. 19
Figura 4 Esempio di Determinazione del prezzo di equilibrio 21
Figura 5 Schema di funzionamento di una RNN 29
Figura 6 Schema di funzionamento LSTM..... 30
Figura 7 Rappresentazione stato di cella 31
Figura 8 Rappresentazione Forget Gate 32
Figura 9 Rappresentazione Input Gate..... 33
Figura 10 Rappresentazione Aggiornamento stato di Cella 33
Figura 11 Rappresentazione Output Gate 34
Figura 12 Rappresentazione delle Celle 34
Figura 13 Rappresentazione rete BiLSTM 36
Figura 14 Rappresentazione CNN 38
Figura 15 Ciclo di ottimizzazione degli iperparametri..... 43
Figura 16 Andamento prezzo giornaliero dell' energia 2024 46
Figura 17 Andamento del prezzo orario 4 aprile 47
Figura 18 Andamento del prezzo orario 7 Aprile 2024..... 48
Figura 19 Andamento del prezzo orario 5 Dicembre 2024..... 48
Figura 20 Andamento del prezzo orario 10 Agosto 2024..... 49
Figura 21 Scatter plot aggregato gennaio 50
Figura 22 Scatter plot aggregato Luglio..... 51
Figura 23 Confronto Distribuzione delle Fluttuazioni Orarie..... 52
Figura 24 Mappa di Densità aggregata Luglio..... 54
Figura 25 Mappa di Densità aggregata Gennaio..... 54
Figura 26 Rappresentazione architettura CNN-Bi-LSTM -ATT 65
Figura 27 Andamento Loss function della LSTM oraria..... 73
Figura 28 Andamento Loss function della LSTM oraria..... 73
Figura 29 Andamento Loss function della CNN-LSTM oraria 74
Figura 30 Andamento Loss Function della CNN-Bi LSTM oraria..... 74
Figura 31 Andamento Loss Function della CNN-Bi LSTM con Attention oraria 75
Figura 32 Andamento Loss Function della LSTM giornaliera 76
Figura 33 Andamento Loss Function della BiLSTM giornaliera 76

Figura 34 Andamento Loss Function della CNN-LSTM giornaliera 77
Figura 35 Andamento Loss Function della CNN-BiLSTM giornaliera 77
Figura 36 Andamento Loss Function CNN-BiLSTM con attention giornaliera 78
Figura 37 Confronto settimanale della previsione oraria autunnale LSTM .. 85
Figura 38 Confronto settimanale della previsione oraria invernale BiLSTM 85
Figura 39 Confronto settimanale della previsione oraria primaverile LSTM86
Figura 40 Confronto settimanale della previsione oraria estiva BiLSTM 86
Figura 41 Confronto settimanale della previsione giornaliera autunnale CNN-BiLSTM 87
Figura 42 Confronto settimanale della previsione giornaliera invernale BiLSTM..... 88
Figura 43 Confronto settimanale della previsione giornaliera primaverile CNN-BiLSTM 88
Figura 44 Confronto settimanale della previsione giornaliera estiva CNN-BiLSTM..... 88
Figura 45 Andamento del prezzo orario nel periodo primaverile..... 91

Indice delle tabelle

Tabella 1 Produzione annuale netta per fonte [GWh] 15
Tabella 2 Tabella delle occorrenze negative della mappa di densità 55
Tabella 3 Tabella delle occorrenze positive della mappa di densità 56
Tabella 4 Accuratezza di previsione oraria per il test set nel periodo autunnale 80
Tabella 5 Accuratezza di previsione oraria per il test set nel periodo invernale 80
Tabella 6 Accuratezza di previsione oraria per il test set nel periodo primaverile 81
Tabella 7 Accuratezza di previsione oraria per il test set nel periodo estivo 81
Tabella 8 Accuratezza di previsione giornaliera per il test set nel periodo autunnale 82
Tabella 9 Accuratezza di previsione giornaliera per il test set nel periodo invernale 82
Tabella 10 Accuratezza di previsione giornaliera per il test set nel periodo primaverile 83
Tabella 11 Accuratezza di previsione giornaliera per il test set nel periodo estivo 83
Tabella 12 Risultati delle Architetture che minimizzano il MAE 92

Capitolo 1 – Introduzione e contesto del sistema elettrico

Il presente capitolo ha l'obiettivo di introdurre il problema oggetto della tesi e di fornire il contesto tecnico-istituzionale necessario per comprenderne la rilevanza. In primo luogo, viene analizzato il valore strategico della previsione dei prezzi dell'energia elettrica sul mercato del Giorno Prima, evidenziandone l'importanza per i principali operatori del sistema, in secondo luogo viene fornita una disamina critica dello stato dell'arte, volta a evidenziare le limitazioni metodologiche degli approcci attuali. Successivamente, viene fornita una descrizione del sistema elettrico nazionale, con riferimento alla struttura della filiera e al mix produttivo italiano. Infine, il capitolo si conclude con un'analisi della struttura del mercato elettrico italiano, approfondendo i meccanismi di funzionamento dei segmenti di mercato rilevanti per la formazione del prezzo oggetto di previsione.

1.1 La previsione dei prezzi elettrici Day-Ahead

L' evoluzione del mercato elettrico, caratterizzata dalla crescente penetrazioni di fonti rinnovabili e non programmabili, ha trasformato radicalmente la struttura dei prezzi, modificandone la variabilità. In questo contesto la capacità di anticipare queste fluttuazioni con un orizzonte temporale di breve termine (Day-Ahead) diviene, pertanto, un asset strategico fondamentale per alcuni operatori. Per questa motivazione, previsioni accurate dei prezzi risultano essere di vitale importanza per svariati attori della filiera, sia dal lato dell' offerta ,sia dal lato della domanda, a titolo di esempio :

- **Produttori**: In particolare per le centrali a ciclo combinato a gas naturale (CCGT), la previsione dei prezzi è la base per ottimizzare le strategie di offerta (bidding) e massimizzare i ricavi attraverso la risoluzione del problema dello *Unit Commitment* (l'impegno delle unità produttive). L'avviamento di una centrale termoelettrica, infatti, comporta costi fissi elevati (consumo di combustibile in fase di start-up, usura dei componenti) e vincoli tecnici temporali, per questa motivazione il produttore deve conoscere in anticipo il profilo di prezzo delle 24 ore successive per massimizzare il profitto atteso.
- **Consumatori**: Un ulteriore ambito di applicazione cruciale riguarda il lato della domanda, specificamente per le industrie energivore

caratterizzate da processi produttivi "a lotti" o semi-continui, che mantengono un certo grado di flessibilità nella pianificazione della produzione. Questi attori non subiscono passivamente il prezzo, ma possono modulare il prelievo in base alla previsione. Per esempio conoscendo il profilo dei prezzi del giorno dopo si può pianificare l'accensione dei macchinari più energivori nelle fasce orarie in cui si prevede un calo del prezzo.

In definitiva, la previsione del prezzo elettrico su orizzonte giornaliero non è una mera speculazione finanziaria, ma uno strumento di efficienza industriale. Essa permette ai produttori di razionalizzare l'uso degli impianti, riducendo sprechi e usura, e consente ai consumatori industriali di trasformare la bolletta energetica da costo fisso a variabile gestibile. Le metodologie di previsione analizzate e proposte in questo elaborato si inseriscono proprio in questo contesto operativo, fornendo il supporto analitico necessario per prendere queste decisioni complesse in condizioni di incertezza. Tuttavia, la previsione dei prezzi elettrici Day-Ahead rappresenta un problema particolarmente complesso dal punto di vista modellistico. La dinamica dei prezzi è influenzata da molteplici fattori interdipendenti, tra cui la variabilità della produzione da fonti rinnovabili, il prezzo dei combustibili fossili, i vincoli fisici della rete di trasmissione, la presenza di congestioni interzonali, le previsioni meteorologiche e il comportamento strategico degli operatori di mercato. Tali elementi generano serie temporali fortemente non lineari e non stazionarie, caratterizzate da eventi estremi, rendendo limitata l'efficacia dei modelli predittivi tradizionali. Il prezzo spot dell'energia elettrica presenta inoltre caratteristiche peculiari che lo distinguono in modo sostanziale da quello di altre commodity energetiche, quali gas naturale, carbone o petrolio. A differenza di queste ultime, l'energia elettrica non può essere immagazzinata in modo efficiente: le tecnologie di accumulo, pur in costante evoluzione, non hanno ancora raggiunto un livello di maturità tale da renderle economicamente e tecnicamente sostenibili su larga scala. Ne consegue che la produzione, il trasporto e il consumo di energia elettrica devono essere bilanciati istante per istante, poiché l'energia generata deve essere necessariamente consumata nello stesso momento in cui viene prodotta.

Questa peculiarità rende il prezzo spot estremamente sensibile alle variazioni della domanda e dell'offerta. Le riserve di capacità disponibili per far fronte a improvvisi incrementi della domanda risultano limitate e, in presenza di vincoli di rete o indisponibilità degli impianti, anche modeste variazioni dei volumi richiesti possono tradursi in oscillazioni di prezzo significative. Tali dinamiche accentuano la volatilità del mercato e rendono particolarmente

complesso il processo di previsione dei prezzi su orizzonti temporali di breve periodo

1.2 Obbiettivi e Definizione del problema

Sebbene la letteratura abbondi di proposte architetturali sempre più complesse, esiste una problematica metodologica di fondo che ne limita spesso l' applicabilità operativa: la mancanza di standardizzazione nei protocolli di validazione. Gran parte degli studi attuali tende a validare i modelli su finestre temporali ridotte o su dataset specificatamente selezionati per esaltare le performance di una singola architettura , trascurando la capacità di generalizzazione su lunghi periodi.

Inoltre, è fondamentale sottolineare come la comparazione diretta con la letteratura pregressa risulti intrinsecamente complessa, poiché ogni studio costituisce un unicum sperimentale, vincolato a specifiche condizioni al contorno che ne delimitano la validità a una precisa finestra temporale, a uno specifico dataset e a specifiche variabili, rendendo i risultati difficilmente replicabili in scenari di mercato diversi. Tali esperimenti isolati, rischiano di produrre risultati sovrastimati che non riflettono la robustezza del modello di fronte a cambi di regime stagionale.

Il presente lavoro di tesi si propone l'obiettivo di colmare questa lacuna, spostando il focus dalla creazione del modello perfetto alla valutazione comparativa. Il problema non viene affrontato proponendo un'unica soluzione, ma istituendo un campo di prova imparziale in cui cinque distinte architetture vengono messe in competizione diretta su due orizzonti temporali diversi. La validazione sperimentale qui condotta non si limita a periodi favorevoli, ma copre un intero anno solare, obbligando i modelli a confrontarsi con tutte le stagionalità, inclusi i periodi critici. L' obiettivo è quindi stabilire quale architettura sopravviva realmente alla volatilità strutturale del mercato elettrico italiano, sia su orizzonte orario che giornaliero.

1.3 Il sistema elettrico nazionale

Iniziamo fornendo una breve descrizione del sistema elettrico italiano, il cui funzionamento è garantito dall'interazione di soggetti istituzionali e operatori, in modo particolare l'architettura del sistema è articolata in quattro fasi fondamentali[1]:

- Produzione
- Trasmissione
- Distribuzione
- Utenze

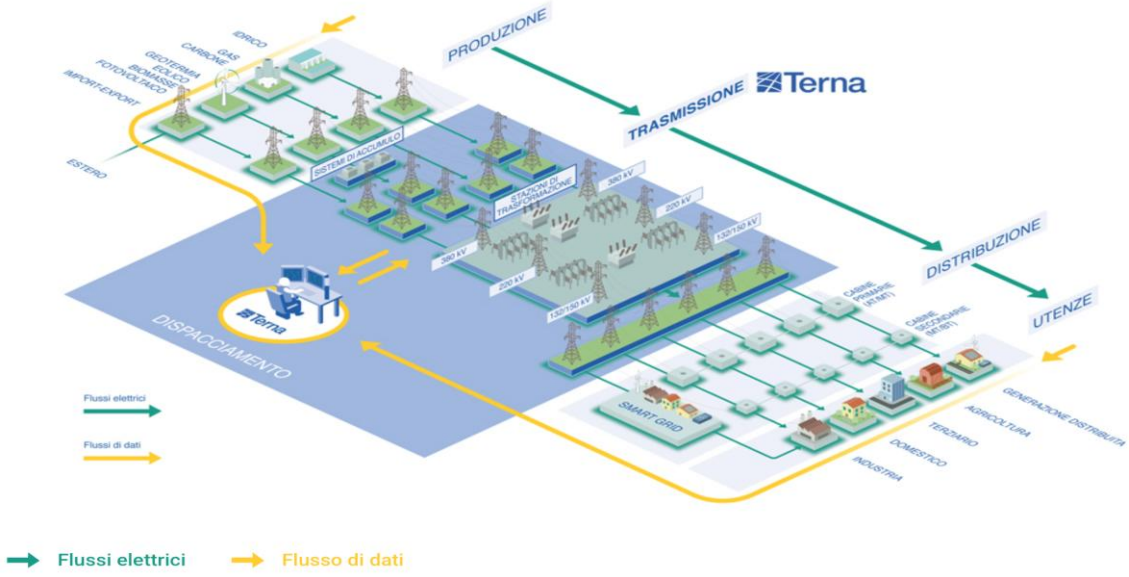

Figura 1 Sistema elettrico italiano

A monte troviamo la produzione di elettricità che opera in un regime di libero mercato mentre la fase centrale della filiera è occupata dalla trasmissione e dal dispacciamento, attività gestite da Terna S.p.A. In qualità di Transmission System Operator (TSO) nazionale, Terna opera in un regime di monopolio naturale (una configurazione diffusa a livello europeo) e sotto la regolazione dell'ARERA. La sua responsabilità copre la gestione, la manutenzione e lo

sviluppo della rete elettrica ad alta e altissima tensione. Il dispacciamento invece è una attività cruciale per amministrare i flussi di energia e assicurare il costante equilibrio tra domanda e offerta. Inoltre, per garantire la concorrenza negli altri segmenti, Terna non opera nelle altre fasi che sono svolte in concorrenza. A valle della filiera si trova la distribuzione, che consiste nella gestione delle reti locali per la consegna capillare ai clienti finali, e la commercializzazione dell'energia, svolta da diverse società in concorrenza.

Il coordinamento di questa filiera e la definizione delle sue regole strategiche e operative sono affidati a specifici soggetti istituzionali, oltre al Parlamento e al Governo:

- Il Ministero dell'Ambiente e della Sicurezza Energetica (MASE): Definisce gli indirizzi strategici ed operativi per garantire la sicurezza, l'economicità e lo sviluppo sostenibile del sistema.
- L'Autorità di Regolazione per Energia Reti e Ambiente (ARERA): È l'organo indipendente con funzioni di regolazione e controllo, preposto a garantire la promozione della concorrenza e dell'efficienza nei servizi di pubblica utilità.
- Il Gestore dei Mercati Energetici (GME): Organizza e gestisce il mercato energetico (la "borsa elettrica") secondo criteri di neutralità, trasparenza, obiettività e concorrenza tra i produttori.
- Il Gestore dei Servizi Energetici (GSE): Holding pubblica che attua le politiche di sostenibilità, gestendo i meccanismi di incentivazione per le fonti rinnovabili.
- L'Acquirente Unico (AU): Società pubblica cui è affidata, tra le altre, la funzione di approvvigionamento centralizzato dell'energia all'ingrosso per rifornire gli esercenti del servizio di vulnerabilità.

Nonostante tutte le fasi siano ugualmente determinanti per il corretto funzionamento del sistema elettrico, di seguito viene approfondita esclusivamente la fase associata alla produzione, in quanto questa risulta fondamentale per la determinazione dei prezzi.

1.3.1 Il mix produttivo italiano

L'energia elettrica è un vettore energetico: bisogna quindi produrla, trasformando l'energia ricavata da fonti primarie. La produzione di energia elettrica in Italia avviene ancora oggi in gran parte sfruttando fonti non rinnovabili, prima fra tutte il gas naturale, che rappresenta la colonna portante della nostra generazione termoelettrica. Si utilizzano ancora, seppur in fase di progressiva dismissione, centrali a carbone e in misura minore altri prodotti petroliferi. Questa dipendenza dalle fonti fossili, che spesso dobbiamo importare, ci espone alle fluttuazioni dei prezzi internazionali e ha un impatto climatico significativo. Tuttavia, è in continuo e rapido aumento lo sviluppo delle fonti rinnovabili, che negli ultimi anni hanno raggiunto quote record, arrivando a coprire oltre il 40% del fabbisogno elettrico nazionale.

Anno	Eolico	Fotovoltaico	Geotermoelettrico	Idrico	Termoelettrico
2000	562.53	6.17	4,415.45	50,229.22	208,079.31
2001	1,177.29	4.78	4,256.32	53,252.26	207,274.55
2002	1,403.25	4.01	4,385.06	46,620.45	218,370.90
2003	1,456.78	4.93	5,035.96	43,649.71	230,035.84
2004	1,843.87	3.98	5,127.19	49,283.74	233,763.85
2005	2,338.13	3.93	5,021.79	42,356.93	240,887.12
2006	2,963.72	2.25	5,207.67	42,882.69	250,169.59
2007	4,032.34	38.95	5,242.76	37,962.28	254,022.70
2008	4,852.40	192.88	5,197.62	46,672.55	250,149.07
2009	6,484.94	676.41	5,015.83	52,843.26	216,086.87
2010	9,047.69	1,874.36	5,046.47	53,795.24	220,983.96
2011	9,774.35	10,668.02	5,315.22	47,202.09	218,486.10
2012	13,333.02	18,637.04	5,251.75	43,256.38	207,327.32
2013	14,811.56	21,228.66	5,320.08	54,068.39	183,403.93
2014	15,088.63	21,837.47	5,566.62	59,574.94	167,080.22
2015	14,705.77	22,587.51	5,823.86	46,450.42	182,860.62
2016	17,522.49	21,757.27	5,867.14	43,784.62	190,771.08
2017	17,565.33	24,016.82	5,821.46	37,556.72	200,305.32
2018	17,556.81	22,265.36	5,757.32	49,929.00	184,336.12
2019	20,034.40	23,319.78	5,688.80	47,590.06	187,317.02
2020	18,608.20	24,551.02	5,646.85	48,951.85	173,890.06
2021	20,723.60	24,632.68	5,535.51	46,919.31	182,234.12
2022	20,304.30	27,674.02	5,449.34	29,904.00	191,276.29
2023	23,373.34	30,235.80	5,318.12	41,478.90	156,155.60
2024	22,087.79	35,398.16	5,407.04	53,975.51	146,360.81

Tabella 1 Produzione annuale netta per fonte [GWh]

La fonte rinnovabile storica dell'Italia è l'energia idroelettrica, prodotta dalle centrali su Alpi e Appennini, la cui produzione è fondamentale ma dipende molto dalle precipitazioni annue. Accanto a questa, sono in fortissima crescita l'energia solare, grazie all'installazione capillare di pannelli fotovoltaici, e l'energia eolica, con parchi eolici concentrati soprattutto nel Sud e nelle Isole. Infine, l'Italia vanta una specifica produzione di energia geotermica, che sfrutta il calore naturale della Terra, concentrata quasi esclusivamente in Toscana. Nonostante la crescita della produzione interna, sia fossile che rinnovabile, questa non è sufficiente a coprire l'intero fabbisogno energetico italiano. Per questo motivo, è necessario acquistare una quota significativa di elettricità da altri Paesi. Questa energia importata viaggia attraverso una complessa rete di elettrodotti ad altissima tensione, circa 30 interconnessioni gestite da Terna che ci collegano ai Paesi vicini. La gran parte dell'elettricità che importiamo proviene storicamente dalla Francia, la cui produzione è dominata dall'energia nucleare, e dalla Svizzera, che sfrutta la sua enorme capacità idroelettrica.

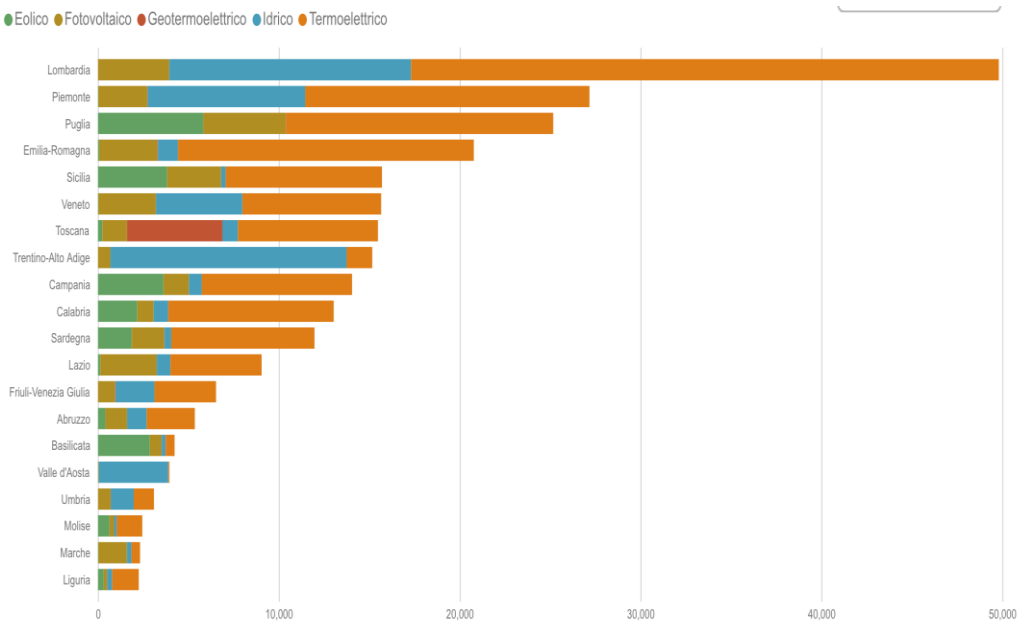

Figura 2 Produzione netta per fonte e regione nell' anno 2024

1.4 Struttura del mercato elettrico

Dopo aver descritto brevemente il sistema elettrico possiamo introdurre la struttura del mercato elettrico, il mercato elettrico è presidiato dal gestore dei mercati elettrici (GME) controllato dal gestore dei servizi energetici (GSE) [2].

L' attuale configurazione del mercato elettrico italiano ha preso avvio con il percorso di liberalizzazione del settore energetico, formalmente avvenuto con il Decreto Legislativo n. 79 del 16 marzo 1999, noto come Decreto Bersani la cui finalità era introdurre principi di concorrenza nelle attività di produzione e vendita di energia elettrica, fino ad allora gestite in regime di monopolio [3].

Come indicato nel vademecum della borsa elettrica aggiornato al 29 settembre 2025 [2], il 1° aprile del 2004 sono iniziate le negoziazioni dando origine alla prima fase del mercato che l'anno seguente, con l'avvio della partecipazione attiva della domanda ha permesso ai grandi consumatori e ai fornitori di acquistare energia direttamente sulla borsa. Due le ragioni alla base del cambiamento, da un lato stimolare la competizione attraverso la concorrenza e spingere dunque verso una diminuzione dei prezzi; dall'altro aumentare trasparenza e simmetria informativa. Infine, il mercato fornisce segnali di prezzo accurati e puntuali che sono cruciali in situazioni di scarsità di offerta, incentivando da un lato i produttori a rendere disponibile la capacità di generazione necessaria e dall'altro i consumatori a un uso più efficiente dell'energia.

Il mercato è il luogo in cui seguendo il criterio di merito economico, vengono stabiliti i prezzi orari e con un giorno di anticipo, i programmi vincolanti di immissione e prelievo sulla rete, essenziali per prevenire congestioni. La partecipazione alla borsa non è obbligatoria, infatti è possibile negoziare contratti bilaterali chiamati contratti OTC (Over The Counter), che avvengono senza intermediari. La struttura principale del mercato si articola in due macro-sezioni: il Mercato a Pronti (MPE)e il Mercato a Termine (MTE):

- Il mercato a Termine non risponde a logiche operative, bensì di gestione del rischio, è la sede di negoziazione per contratti di energia elettrica con obbligo di consegna e ritiro futuro su orizzonti temporali

estesi (mensili,trimestrali e annuali) È un meccanismo fondamentale per ridurre e mitigare l' esposizione alla variabilità dei prezzi: bloccando il prezzo di vendita e acquisto ex-ante, gli operatori possono garantire stabilità e proteggere i margini operativi dalle fluttuazioni giornaliere di domanda e offerta.

- Nel mercato a pronti si negoziano blocchi di energia con consegna immediata o per il giorno successivo, sede comunemente chiamata "borsa elettrica". È in questo contesto che viene determinato il prezzo di riferimento nazionale, recentemente oggetto di riforma. Nello specifico, il **PUN Index GME** subentra allo storico PUN come nuovo indicatore di riferimento. Come stabilito e citato testualmente nella delibera **304/2024/R/eel** dell'ARERA [4]: *'A partire dal 1° gennaio 2025, GME pubblicherà un prezzo di riferimento (il PUN Index GME) calcolato, in maniera del tutto analoga all'odierno PUN, come media dei prezzi zonali ponderata per le quantità acquistate'*.

Il Mercato a Pronti nello specifico è suddiviso in quattro sezioni:

- Mercato del Giorno Prima (MGP): dove i produttori e clienti finali idonei possono acquistare e vendere energia elettrica per il giorno successivo;
- Mercato Infragiornaliero (MI): costituito da due sessioni MI-A e MI-XBID, nelle quali avviene una correzione o conferma delle posizioni commerciali di immissione e prelievo definiti sul MGP;
- Mercato dei prodotti giornalieri (MPEG): ovvero la sede di negoziazione delle offerte di acquisto e vendita dei prodotti giornalieri;
- Mercato per il bilanciamento e redispacciamento (MSD):è l'Integrated Scheduling Process ovvero la sede di approvvigionamento da parte di Terna delle risorse per il servizio di bilanciamento e redispacciamento, articolato nelle sessioni previste nella disciplina del dispacciamento.

Il sistema elettrico italiano per vincoli di natura geografica e fisica è suddiviso in sette "zone di mercato" territoriali (visibili in Figura 2.2): Nord, Centro-

Nord, Centro-Sud, Sud, Calabria, Sicilia e Sardegna. All'interno di ogni area, la compravendita avviene senza restrizioni e si determina un "prezzo zonale" specifico.

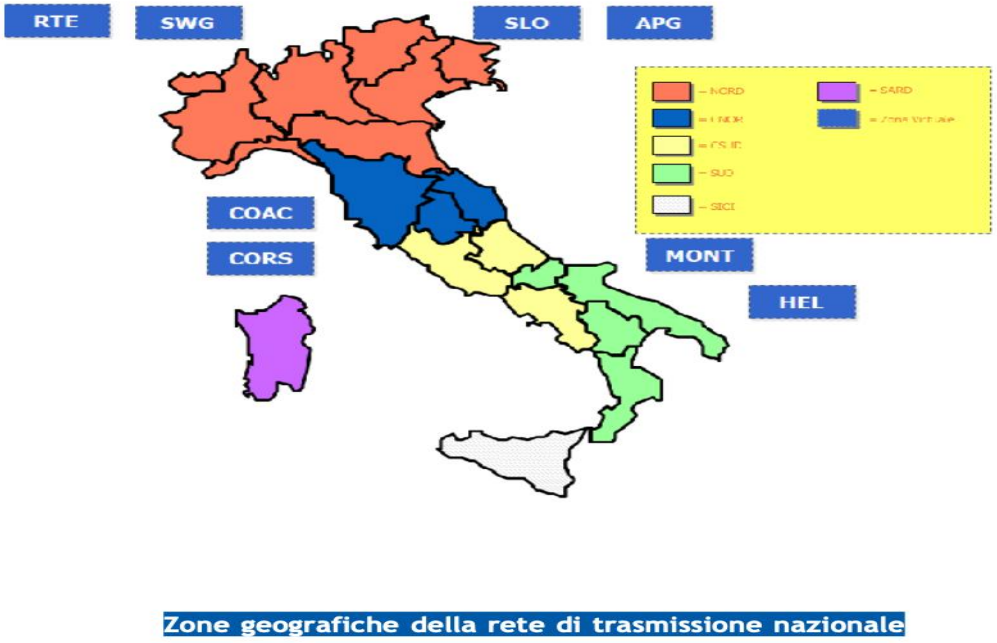

Figura 3 Mappa delle zone geografiche del mercato elettrico nazionale [9].

Come osservato in questo capitolo il mercato elettrico italiano si articola in diversi segmenti, ciascuno con finalità e meccanismi operativi diversi. In un'ottica di completezza descrittiva è stata fornita una panoramica per comprenderne meglio il funzionamento.

Tuttavia, ai fini della presente tesi è necessario delimitare l'ambito di mercato ai segmenti rilevanti per la formazione del segnale di prezzo oggetto di previsione. In particolare, la modellazione si concentra sulla previsione dei prezzi zonali orari del Mercato del Giorno Prima (MGP), che rappresentano il principale riferimento economico per gli operatori e costituiscono la base delle decisioni di programmazione della produzione e del consumo.

Il Mercato Infragiornaliero (MI) viene pertanto approfondito in quanto segmento strettamente collegato al MGP e funzionale alla gestione degli

scostamenti rispetto ai programmi definiti il giorno precedente. La sua analisi consente di inquadrare correttamente il contesto operativo in cui si inserisce il prezzo del MGP e di comprendere le dinamiche di aggiustamento che intervengono in prossimità del tempo reale.

1.4.1 Il Mercato del Giorno Prima (MGP)

Nel Mercato del Giorno Prima (MGP) si concentra la quota preponderante delle transazioni di compravendita di energia elettrica. In tale mercato gli operatori presentano offerte di vendita e di acquisto riferite a blocchi di energia per ciascun intervallo orario del giorno successivo.

L' MGP opera come un mercato d'asta a prezzo uniforme, risolto separatamente per ciascuna ora e tenendo conto della suddivisione del sistema elettrico nazionale in zone di mercato predefinite. Le offerte di vendita esprimono la disponibilità a immettere in rete una determinata quantità di energia a un prezzo minimo accettabile, mentre le offerte di acquisto indicano la disponibilità a prelevare una determinata quantità a un prezzo massimo disposto a pagare.

Per ciascuna ora, tutte le offerte valide vengono aggregate e ordinate: le offerte di vendita in ordine crescente di prezzo e quelle di acquisto in ordine decrescente. L'esito del mercato è determinato tramite un algoritmo che massimizza il surplus complessivo, nel rispetto dei vincoli di capacità di transito della rete di trasmissione tra le diverse zone.

Figura 4 Esempio di Determinazione del prezzo di equilibrio

Nel caso in cui non si verifichino congestioni di rete, il mercato presenta un prezzo unico nazionale di equilibrio (P*), valido per tutte le zone.

Qualora, invece, uno o più vincoli di transito interzonali risultino saturi, il mercato viene risolto tenendo conto delle limitazioni di flusso tra le zone interessate. In questo caso si determina un esito zonale, con la formazione di prezzi zonali (Pz) differenziati. In presenza di congestione, le zone con saldo netto di importazione presentano generalmente un prezzo più elevato, mentre le zone con saldo netto di esportazione presentano un prezzo più basso. L'algoritmo risolve simultaneamente l'intero sistema, garantendo la

compatibilità con tutti i vincoli di rete, senza ricorrere a suddivisioni iterative del mercato.

Il prezzo zonale si applica ai portafogli di immissione appartenenti alla medesima zona. Per quanto riguarda i portafogli in prelievo, a seguito delle modifiche introdotte dal D.M. MASE del 18 aprile 2024 e dalla Deliberazione ARERA 304/2024/R/eel [2], il prezzo di riferimento è rappresentato dal PUN Index GME ottenuto con una componente compensativa. Tale componente, calcolata dal GME come prodotto tra la quantità accettata e la differenza tra il prezzo zonale e il PUN Index GME, può assumere valore positivo o negativo e viene rispettivamente riconosciuta o addebitata all'operatore.

Il meccanismo di market splitting che emerge in presenza di congestioni può essere interpretato come una procedura di allocazione implicita e non discriminatoria della capacità di transito, nella quale l'assegnazione dei flussi interzonali avviene contestualmente alla determinazione dei prezzi e delle quantità scambiate, senza la separazione di mercati per i diritti di trasmissione.

La curva di offerta del mercato riflette la struttura dei costi degli impianti di generazione. In particolare, i produttori da fonti rinnovabili, caratterizzati da costi variabili prossimi allo zero, tendono a presentare offerte a prezzi molto bassi per massimizzare la probabilità di accettazione. In presenza di impianti con produzione non modulabile, obblighi di immissione o vincoli di sicurezza del sistema, nonché di specifiche condizioni di mercato e di incentivazione, possono verificarsi prezzi prossimi allo zero.

Il meccanismo di remunerazione adottato nel MGP è quello del System Marginal Price: tutte le unità di energia accettate vengono remunerate al prezzo dell'offerta marginale, ossia l'offerta più costosa necessaria per soddisfare la domanda complessiva.

A titolo di esempio, si consideri una domanda pari a 10 GW e le seguenti offerte di vendita:

- Produttore A: 5 GW a 50 €/MWh
- Produttore B: 3 GW a 60 €/MWh
- Produttore C: 4 GW a 70 €/MWh

Per soddisfare la domanda, il mercato accetta integralmente le offerte di A e B (per un totale di 8 GW) e parzialmente l'offerta di C per i restanti 2 GW. L'offerta di C, pari a 70 €/MWh, risulta marginale; di conseguenza, tutta l'energia accettata viene remunerata a tale prezzo. Questo meccanismo incentiva l'efficienza produttiva e favorisce gli operatori caratterizzati da costi marginali inferiori.

1.4.2 Il Mercato Infragiornaliero (MI)

Il Mercato Infragiornaliero (MI) rappresenta il segmento del mercato elettrico dedicato all'aggiustamento delle posizioni commerciali di immissione e prelievo precedentemente definite sul Mercato del Giorno Prima (MGP). Esso consente agli operatori di modificare i programmi di produzione e consumo sulla base di informazioni più aggiornate, disponibili in una fase temporale più prossima al dispacciamento.

Il ruolo del MI è divenuto progressivamente più rilevante con l'aumento della penetrazione delle fonti rinnovabili non programmabili, la cui produzione è caratterizzata da un'elevata incertezza previsionale. In tale contesto, il MI permette di gestire gli scostamenti tra le previsioni formulate il giorno prima e le condizioni effettive di domanda e offerta che emergono in prossimità dell'esercizio.

Il Mercato Infragiornaliero si articola in due segmenti distinti, coerenti con il Target Model europeo: il Mercato Infragiornaliero ad Asta (MI-A) e il Mercato Infragiornaliero a Negoziazione Continua (MI-XBID). Entrambi i segmenti operano secondo meccanismi di allocazione implicita della capacità di transito tra le zone di mercato, consentendo l'aggiustamento delle posizioni commerciali nel rispetto dei vincoli di rete.

A differenza dell' MGP, l' MI non rappresenta il principale meccanismo di formazione del prezzo di riferimento del sistema elettrico, bensì uno strumento di ribilanciamento che consente agli operatori di correggere le proprie esposizioni. I prezzi che emergono sul MI riflettono quindi

informazioni più puntuali e contingenti, spesso legate a eventi imprevisti, e risultano fortemente influenzati da fattori di breve periodo.

Per queste ragioni, nell'ambito della presente tesi, l'attenzione è rivolta alla previsione dei prezzi zonali del Mercato del Giorno Prima, che costituiscono il principale segnale economico per le decisioni di offerta e domanda e rappresentano il riferimento fondamentale per la pianificazione delle strategie degli operatori. L' MI viene pertanto considerato come elemento di contesto, utile a spiegare la presenza di aggiustamenti successivi e la complessità complessiva del sistema, ma non come oggetto diretto dell'attività di previsione.

Capitolo 2 – Stato dell' arte e fondamenti teorici

Per affrontare la complessità del problema, la ricerca scientifica ha assistito negli anni a un progressivo spostamento dai modelli statistici tradizionali verso tecniche basate sull' intelligenza artificiale. Il presente capitolo si propone di inquadrare il lavoro svolto all' interno del panorama scientifico e metodologico. Nella prima parte (Sezione 2.1), viene presentata una disamina della letteratura, evidenziando le evoluzioni delle tecniche di forecasting : dai metodi classici all' affermazione del Deep Learning come nuovo standard. Successivamente, verranno approfonditi i fondamenti teorici necessari alla comprensione dei modelli implementati. Partendo dai concetti basilari delle Reti Neurali Artificiali (Sezione 2.2), verranno descritte le limitazioni delle reti neurali tradizionali. Infine nelle sezioni successive verranno analizzate in dettaglio le architetture utilizzate in questo studio, illustrando come la loro integrazione permetta di catturare efficacemente le dipendenze temporali a lungo termine e pattern presenti nei dati.

2.1 La letteratura scientifica

In letteratura, le metodologie di forecasting per le serie storiche possono essere suddivise in due macrocategorie: i modelli statistici classici e quelli basati sull'Intelligenza Artificiale. I primi, come AR, ARMA e ARIMA, approssimano la funzione di partenza scomponendola in componenti elementari. Sebbene tali approcci siano stati per decenni lo standard grazie alla loro semplicità, presentano limiti significativi nella gestione di dati caratterizzati da non-stazionarietà e non-linearità, come quelli dei moderni mercati elettrici. Ad esempio, Lu et al. [5] mostrano come, nel mercato australiano, la crescente penetrazione delle rinnovabili aumenti l'incertezza al punto da mettere in difficoltà i modelli lineari.

Per superare tali limiti, la ricerca si è orientata verso algoritmi di Machine Learning. Al-Musaylh et al. [6], ad esempio, mostrano come il Support Vector Regression (SVR), combinato con tecniche di ottimizzazione, possa superare i modelli tradizionali. Nella stessa direzione, Zhao et al. [7] propongono un framework basato su metodi di Data Mining e Support Vector Machine (SVM),un algoritmo di machine learning per la classificazione, utilizzato per analizzare i picchi di prezzo, dimostrando che trattare i picchi come eventi distinti migliori significativamente la capacità predittiva.

Parallelamente, l'introduzione di tecniche come la Random Forest per la selezione delle variabili, come mostrato da Ludwig et al. [8], permette di ridurre il rumore e migliorare l'efficienza dei modelli. A ciò si aggiungono le Extreme Learning machines ELM, che rinunciano a una struttura profonda per ottenere una velocità di addestramento molto elevata, rendendole adatte a scenari real-time, sebbene abbiano limitazioni nella gestione della memoria a lungo termine. Questi modelli combinati con tecniche di bootstrapping, come proposto da Chen et al. [9], hanno ulteriormente migliorato la stabilità delle previsioni.

Nonostante tali progressi, questi modelli faticano ancora a gestire grandi volumi di dati e a catturare efficacemente le dipendenze temporali. Un contributo significativo in questa direzione è offerto da Jiang et al. [10], che propongono un approccio Multi-Input Multi-Output (MIMO) per prevedere simultaneamente l'intero orizzonte temporale, riducendo la propagazione dell'errore tipica dei modelli ricorsivi.

L'avvento del Deep Learning ha poi aperto nuove prospettive, introducendo architetture capaci di estrarre automaticamente feature complesse. In particolare, Lago et al. [11], confrontando 27 modelli diversi, dimostrano la superiorità delle reti neurali profonde sui modelli statistici tradizionali, affermando il Deep Learning come nuovo standard per la previsione dei prezzi spot.

Tra le architetture più versatili figurano le Long Short-Term Memory (LSTM), sviluppate originariamente per superare il problema del gradiente evanescente nelle RNN. L'applicazione delle LSTM alla previsione di serie

temporali è stata formalizzata da Gers et al. [12], che ne hanno evidenziato la capacità di modellare dipendenze a lungo termine.

Successivi sviluppi hanno portato alla definizione di architetture ibride, come quelle che combinano CNN e Bi-LSTM, integrate con meccanismi di attenzione, come mostrato da Wang et al. [13]. L'uso della bidirezionalità consente di sfruttare contesto passato e futuro, mentre l'attenzione attribuisce pesi dinamici alle informazioni più rilevanti.

Parallelamente, vari studi hanno affrontato la questione dell'ottimizzazione degli iperparametri, spesso critica nei modelli di deep learning. Memarzadeh e Keynia [14] propongono procedure di ottimizzazione automatica che permettono di massimizzare l'accuratezza senza intervento manuale.

La ricerca più recente si concentra su contesti di mercato particolarmente complessi. Deng et al. [15], ad esempio, mostrano come, nei mercati caratterizzati da estrema volatilità, sia fondamentale modellare esplicitamente componenti stagionali. Inoltre, la letteratura evidenzia una distinzione tra approcci basati sulla decomposizione del segnale e approcci basati sulla selezione esplicita delle variabili. A titolo di esempio citiamo il modello VMD-ATT-LSTM di Xu et al. [16] che utilizza la Variational Mode Decomposition per arricchire informazione estraendo componenti IMF dal segnale originale; dall'altro, Alhendi et al. [17] che invece propongono un'architettura ANN-MC che si affida alla conoscenza del dominio utilizzando un set di otto variabili dipendenti di carattere meteorologico e temporale, spiegando così la variabilità della domanda.

In sintesi, la letteratura recente indica che le architetture più promettenti sono quelle ibride, capaci di combinare estrazione automatica di feature (CNN), modellazione sequenziale (LSTM/Bi-LSTM) e meccanismi di attenzione. Questi elementi rappresentano il fondamento del modello proposto nel presente lavoro.

2.2 Fondamenti di reti neurali

L'obiettivo primario di un algoritmo di apprendimento automatico consiste nell'approssimare una funzione obiettivo sconosciuta; nel caso supervisionato questa tenta di descrivere la relazione ideale che intercorre tra un insieme di dati di input e i corrispondenti dati di output. Il processo di apprendimento si configura, pertanto, come un problema di inferenza induttiva [18]. In un problema di questo tipo viene fornito un sottoinsieme di esempi, noto come training set, composto da coppie Input-output e analizzando questi esempi il modello esplora uno spazio di funzioni possibili definito "spazio delle ipotesi" al fine di selezionare una funzione che minimizzi l'errore di approssimazione rispetto alla funzione target. Il criterio di successo di questo processo non risiede nella mera capacità del modello di replicare gli output per gli input già noti, bensì nella sua capacità di generalizzare. Un modello efficace deve essere in grado di produrre output corretti per input mai osservati durante la fase di addestramento; lo scopo è quindi quello di derivare, a partire da dati empirici, un modello che approssimi la funzione generatrice dei dati, garantendo così previsioni accurate e affidabili su nuovi campioni.

Le reti neurali sono ispirate al funzionamento del cervello umano; la struttura fondamentale del Deep Learning è la Rete Neurale Artificiale (ANN) Rosenblatt [19]. Una ANN è composta da nodi interconnessi, detti neuroni, organizzati in strati (layers): uno strato di input che riceve i dati (input layer), strati nascosti (hidden layers) che eseguono le elaborazioni, e uno strato di output che fornisce il risultato finale. Ogni connessione tra neuroni ha un "peso", un parametro numerico che viene aggiornato durante il processo di addestramento. Quando i dati attraversano la rete, ogni neurone calcola una somma pesata degli input che riceve e applica una funzione di attivazione per decidere se e come trasmettere il segnale allo strato successivo. L'addestramento delle reti neurali avviene tramite un processo chiamato backpropagation [20], in cui l'errore commesso dalla rete viene propagato all'indietro per aggiornare i pesi, minimizzando la funzione di perdita. Questo

meccanismo permette alle ANN di apprendere relazioni complesse e non lineari, rendendole efficaci in compiti come la classificazione di immagini o la regressione. Tuttavia, le ANN tradizionali hanno un limite intrinseco: processano ogni input in modo indipendente, senza avere una memoria degli input precedenti. Questo le rende inadatte per analizzare dati sequenziali, come le serie storiche o il linguaggio naturale, dove l'ordine degli elementi è fondamentale. Per superare questa limitazione, sono state introdotte le Reti Neurali Ricorrenti, o RNN [21].

La caratteristica distintiva di una RNN è la presenza di un ciclo interno: l'output di una cella a un certo istante di tempo viene reimmesso come parte dell'input per l'istante successivo. Questo ciclo crea una forma di memoria, permettendo alla rete di conservare informazioni sugli elementi passati della sequenza e di utilizzarle per interpretare quelli futuri.

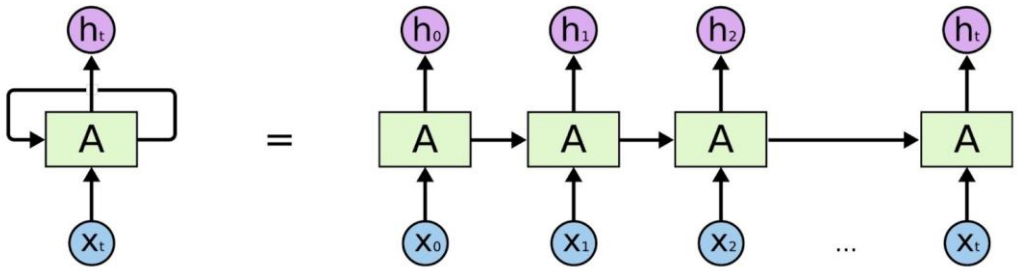

Figura 5 Schema di funzionamento di una RNN

Nonostante la loro eleganza concettuale, le RNN standard soffrono di un grave problema durante l'addestramento, noto come il problema del gradiente evanescente e del gradiente esplosivo [22]. L'addestramento delle reti neurali avviene appunto tramite il processo di backpropagation, in cui l'errore commesso dalla rete viene propagato all'indietro cercando di minimizzare la funzione di perdita. Nelle RNN, questo errore viene propagato attraverso il tempo lungo la sequenza. Se la sequenza è molto lunga, il gradiente, che è il segnale che guida l'aggiornamento, può subire moltiplicazioni ripetute. Se il valore assoluto di questi fattori è inferiore a uno, il gradiente decresce

esponenzialmente fino a svanire, impedendo alla rete di apprendere le dipendenze a lungo termine e facendole "dimenticare" gli eventi iniziali della sequenza. Al contrario, se il modulo è maggiore di uno, il gradiente può crescere a dismisura, portando a un aggiornamento instabile dei pesi e alla divergenza del processo di addestramento. Questa criticità ha reso necessario lo sviluppo di architetture più sofisticate come le LSTM [23], progettate specificamente per controllare il flusso di informazioni e mitigare questi problemi, permettendo di modellare efficacemente le dipendenze a lungo raggio nei dati sequenziali.

2.3 L' Architettura LSTM

Le Long Short-Term Memory (LSTM) sono un particolare tipo di reti neurali ricorrenti (RNN), superano il limite della scomparsa del gradiente che emerge in questo tipo di reti e consentono alla rete di conservare le dipendenze temporali in modo efficace.

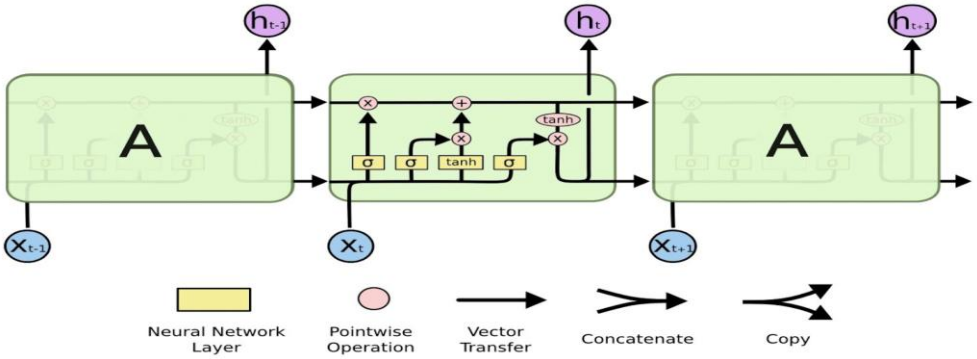

Figura 6 Schema di funzionamento LSTM

Il cuore di un'unità LSTM è lo Stato della Cella *C(t)* può essere interpretato come un canale di memoria a lungo termine che attraversa tutti i moduli. A differenza dello stato nascosto delle RNN classiche, aggiornato in modo esclusivamente moltiplicativo, lo stato della cella viene aggiornato mediante operazioni di somma controllate, garantendo un percorso di propagazione del

gradiente più stabile, spesso visualizzato come un nastro trasportatore che corre attraverso l'intera catena di moduli della rete.

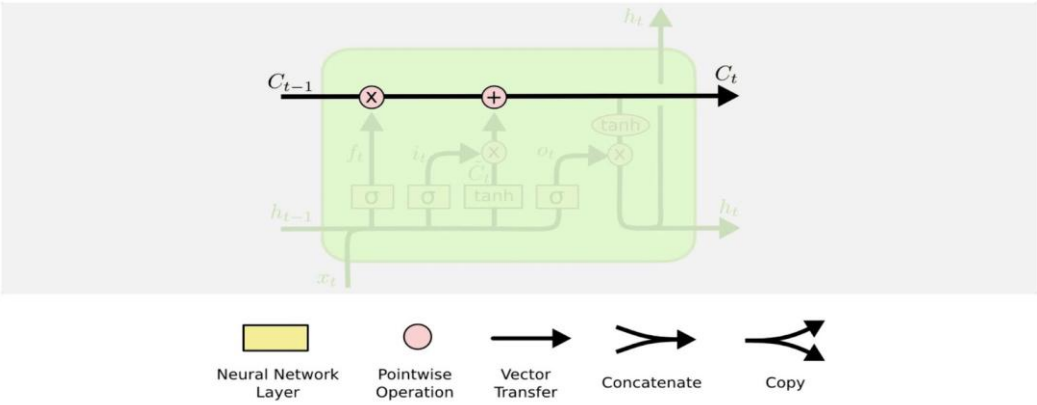

Figura 7 Rappresentazione stato di cella

L'interazione con lo stato della cella è regolata da tre meccanismi fondamentali, detti gate:

1. Forget Gate
2. Input Gate
3. Output Gate

Ogni gate è implementato tramite un livello neurale con attivazione sigmoidale, che produce valori compresi tra 0 e 1 e consente alla rete di modulare selettivamente il flusso dell'informazione.

2.3.1. Forget Gate

Il Forget Gate decide quali componenti della memoria precedente devono essere mantenute o eliminate. Calcolando un vettore:

$$f_t = \sigma\left(W_f[h_{t-1}, x_t] + b_f\right)$$

X(t) è l'input corrente, *h(t-1)* lo stato nascosto precedente, *Wf* la matrice dei pesi e *bf* il bias. Il valore risultante *f(t)* viene applicato elemento per elemento allo stato della cella *C(t-1).*

$$f_t \times C_{t-1}$$

Determinando così quali informazioni della memoria precedente vengono conservate:

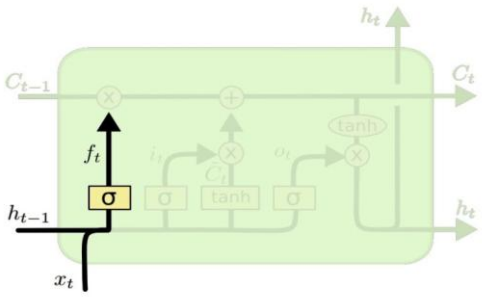

Figura 8 Rappresentazione Forget Gate

2.3.2. Input Gate

L'Input Gate decide quali nuove informazioni dell'input corrente devono essere immagazzinate nello Stato della Cella. Questo processo si articola in due fasi:

- Un primo livello, utilizzando una funzione di attivazione sigmoidale, che determina quali elementi dell'input sono candidati a essere aggiornati:

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i)$$

- Un secondo livello, utilizzando una tangente iperbolica che crea un vettore di valori candidati, ovvero la nuova informazione potenziata:

$$c_t^{\cong} \tanh(W_c[h_{t-1}, x_t] + b_c)$$

Le due quantità vengono combinate per aggiornare la memoria:

$$i_t \times c_t^{\sim}$$

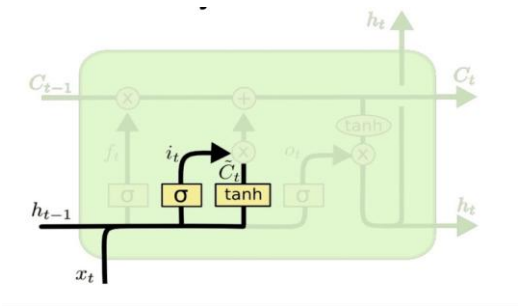

Figura 9 Rappresentazione Input Gate

Infine, lo stato della cella viene aggiornato sommando il contributo mantenuto dal Forget Gate e quello aggiunto dall'Input Gate:

$$Ct = f_t \times C_{t-1} + i_t \times C_t^{\sim}$$

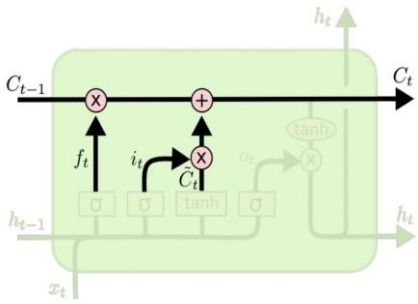

Figura 10 Rappresentazione Aggiornamento stato di Cella

2.3.3. Output Gate

L'Output Gate determina quale parte dello stato della cella deve essere utilizzata per produrre lo stato nascosto corrente:

$$o_t = \sigma(W_o[h_{h-1}, x_t] + b_o)$$

Lo stato nascosto è ottenuto filtrando la versione normalizzata dello stato della cella:

$$h_t = o_t \times \tanh(C_t)$$

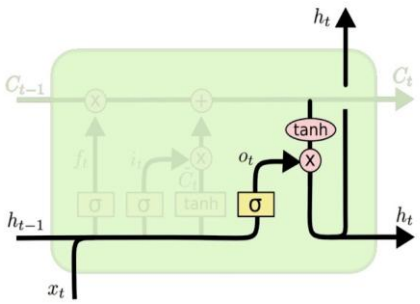

Figura 11 Rappresentazione Output Gate

Lo stato *h(t)* rappresenta sia l'output della cella, sia la memoria a breve termine usata nei passaggi successivi. In sintesi, i gate conferiscono alle LSTM la capacità unica di gestire in modo selettivo le informazioni: dimenticare ciò che è irrilevante, memorizzare ciò che è importante e regolare ciò che viene esposto come output.

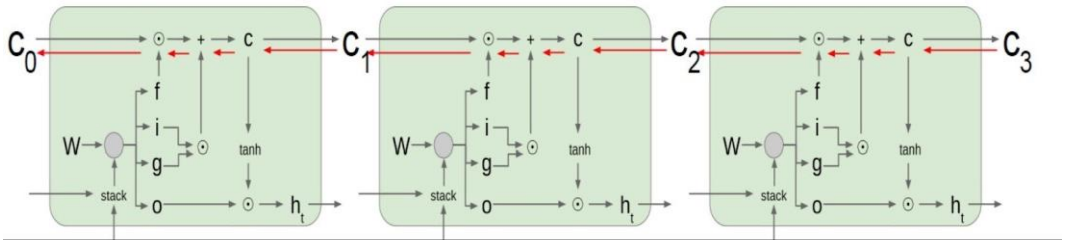

Figura 12 Rappresentazione delle Celle

2.4 Architetture ibride

Nonostante l' efficacia dell' LSTM standard, la ricerca ha prodotto diverse varianti specializzate di architetture ibride, progettate per superare specifiche limitazioni e migliorare le performance in determinati contesti applicativi. Queste estensioni non alterano il meccanismo di base della cella LSTM, ma ne modificano l'impiego a livello architetturale per catturare dipendenze più complesse nei dati. Di seguito vengono analizzate tre delle varianti utilizzate in questo lavoro: le reti bidirezionali, i modelli ibridi convoluzionali e l'integrazione del meccanismo di attenzione.

2.4.1 Reti LSTM Bidirezionali (BiLSTM)

L'architettura LSTM convenzionale processa le sequenze in una sola direzione, in avanti nel tempo, dal passato al futuro. Questo approccio è intuitivo, ma presenta una limitazione fondamentale: la predizione a un dato istante temporale t si basa esclusivamente sulle informazioni passate. In molti problemi, tuttavia, anche il contesto futuro può fornire informazioni cruciali per interpretare correttamente l'istante attuale.

Per ovviare a questa lacuna, sono state introdotte le Reti LSTM Bidirezionali, introdotte da M. Schuster e K. K. Paliwal [24]. Una BiLSTM è costituita da due strati LSTM indipendenti che operano in parallelo sullo stesso input:

1. Uno strato *forward*, che processa la sequenza dall'inizio alla fine.
2. Uno strato *backward*, che processa la sequenza in ordine inverso, dalla fine all'inizio.

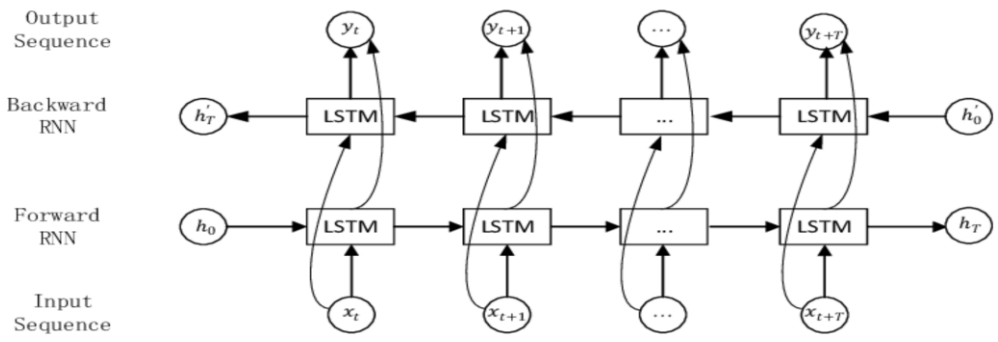

Figura 13 Rappresentazione rete BiLSTM

Per ogni istante temporale t, l'output finale viene generato combinando, solitamente tramite concatenazione, l'output dello stato nascosto *forward* e quello dello stato nascosto *backward*. In questo modo, il modello è in grado di creare una rappresentazione dell'input che tiene conto del contesto completo della sequenza, sia passato che futuro, migliorando significativamente la sua capacità di modellare le dipendenze temporali.

2.4.2 Modelli Ibridi CNN-LSTM

Le reti LSTM rappresentano uno strumento particolarmente efficace per modellare le dipendenze temporali nelle sequenze, ma non sono altrettanto adatte a catturare strutture locali o pattern che si manifestano all'interno di brevi finestre temporali. Le Reti Neurali Convoluzionali (CNN) [25], al contrario, eccellono nell'estrazione di caratteristiche locali grazie all'impiego dell'operazione di convoluzione, che costituisce il meccanismo fondamentale attraverso cui individuano regolarità e strutture ricorrenti nei dati. Una CNN è tipicamente organizzata come una successione di tre layer :convoluzionale, di pooling e di fully connected,che trasformano progressivamente il volume di input in rappresentazioni più compatte e informative. La scelta della dimensione della convoluzione dipende dalla natura dei dati in ingresso. Nel caso di dati sequenziali, come le serie storiche, è comune adottare convoluzioni unidimensionali, in cui il filtro scorre lungo l'asse temporale per identificare pattern locali distribuiti nel tempo. L'architettura ibrida CNN–LSTM combina i punti di forza dei due modelli in una configurazione sequenziale: la CNN svolge il ruolo di estrattore automatico di feature, mentre

l'LSTM si concentra sulla modellazione delle relazioni temporali. In particolare, gli strati convoluzionali applicati inizialmente alla serie storica permettono di individuare pattern locali ricorrenti, come oscillazioni giornaliere o cicli settimanali, che la rete apprende direttamente dai dati. In tale configurazione, l'LSTM non lavora più sui dati grezzi, ma su una sequenza già filtrata e strutturata, risultando quindi più efficace nella cattura delle dinamiche temporali complesse. L'integrazione delle due architetture permette così di modellare simultaneamente pattern locali e dipendenze a lungo termine, ottenendo prestazioni particolarmente competitive in molte applicazioni di forecasting.

Nello specifico il layer convoluzionale effettua una operazione matematica tra l'input I e il kernel (o filtro) W detta appunto convoluzione. In realtà, nei moderni framework di deep learning, l'operazione implementata corrisponde tecnicamente alla cross-correlation, e non alla convoluzione nel senso matematico stretto. Il filtro scorre lungo i dati di input calcolando il prodotto scalare tra i pesi del filtro e la porzione locale di input che sta coprendo in quel momento. In ogni posizione, il filtro si sovrappone a una finestra temporale dell'input; a questo punto la rete esegue una moltiplicazione elemento per elemento tra i valori del kernel $w(k)$ e i corrispondenti valori in input $x(t+k)$. I prodotti ottenuti vengono poi sommati per le K posizioni della finestra (dimensione del kernel) per produrre un singolo valore scalare $S(t)$ nella mappa delle caratteristiche di output, detta feature map. Segue la formula per il caso unidimensionale:

$$S(t) = \sum_{k=0}^{K-1} x(t+k)w(k)$$

Nel caso specifico multivariato l'operazione rimane una convoluzione 1D in quanto il filtro si muove lungo un'unica direzione, ma il kernel non è un semplice vettore, bensì una matrice di dimensione $(K \times F)$, dove F rappresenta il numero di feature (variabili di input) e K la lunghezza temporale del filtro. Questo significa che la convoluzione aggrega informazioni da tutte le feature contemporaneamente all'interno della finestra temporale K. La formulazione generale dell'operatore nel caso multicanale diventa quindi:

$$S(t) = \sum_{k=0}^{K-1} \sum_{f=0}^{F-1} x_f(t+k) w_f(k)$$

L'output di un livello convoluzionale è governato poi da altri iperparametri critici, come lo Stride e il Padding :

- **Stride:** Definisce l'intervallo di scorrimento del filtro. Uno stride pari a 1 significa che il filtro si sposta di una unità alla volta. Uno stride maggiore invece riduce la dimensione spaziale della feature map risultante.
- **Padding:** È una tecnica che ha come scopo il riempimento dell'output. Poiché la convoluzione riduce naturalmente le dimensioni dell'output, si utilizza spesso la tecnica dello Zero-padding, che consiste nell'aggiungere cornici di zeri attorno all'input. Questo permette di controllare la dimensionalità spaziale dell'output, preservando le informazioni ai bordi che altrimenti verrebbero perse.

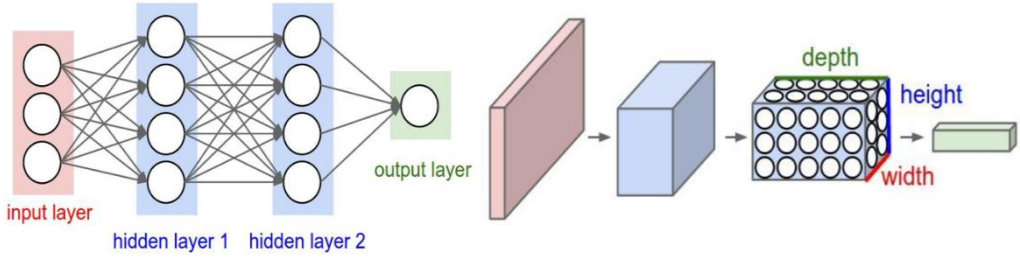

Figura 14 Rappresentazione CNN

Dopo lo strato convoluzionale, le CNN includono tipicamente uno o più layer di pooling e, nelle architetture classiche, uno strato "fully connected". Nel modello proposto in questa tesi, tuttavia, quest'ultimo non viene impiegato.

Il pooling layer ha l'obiettivo di ridurre la dimensionalità delle feature map preservando le informazioni più rilevanti. Tale operazione introduce un'invarianza locale rispetto a traslazioni e piccole perturbazioni del segnale,

migliorando la capacità di generalizzazione del modello e contenendo il costo computazionale.

Le tipologie di pooling più utilizzate sono il Max Pooling e l'Average Pooling:

- il *Max Pooling* seleziona il valore massimo all'interno di ogni finestra locale, enfatizzando le attivazioni più forti; per tali ragioni quest' ultimo è stato implementato all' interno dei modelli.

- l'*Average Pooling*, invece, calcola la media dei valori nella finestra, producendo una rappresentazione più smussata e bilanciata del segnale.

2.4.3 Il Meccanismo di Attenzione

Una delle principali sfide nell'analisi di sequenze molto lunghe è la possibile perdita di informazioni rilevanti provenienti da un passato distante. Sebbene le LSTM contribuiscano a mitigare il problema del gradiente evanescente, la loro capacità di "memorizzare" è comunque limitata dalla dimensione finita dello stato di cella. L' introduzione del meccanismo di attenzione [26], permette al modello di concentrarsi selettivamente sulle parti più rilevanti della sequenza durante la predizione. A differenza delle LSTM tradizionali, che comprimono l'intera cronologia in un unico vettore a dimensione fissa, l'attenzione calcola dei "punteggi di importanza" per ciascun passo temporale. Il modello utilizza questi pesi per generare una somma pesata degli stati nascosti passati, dando maggiore rilievo agli istanti ritenuti più influenti. Questo approccio non solo migliora l'accuratezza, soprattutto in presenza di dipendenze a lungo raggio, ma aumenta anche l'interpretabilità del modello, consentendo di visualizzare quali dati storici hanno maggiormente influenzato una previsione. Nell'architettura proposta, viene adottato un meccanismo di Self-Attention, implementato tramite il layer *tf.keras.layers.Attention.* In questo contesto, gli stati nascosti prodotti dalla BiLSTM vengono utilizzati contemporaneamente come query, key e value, permettendo al modello di confrontare tutte le posizioni della sequenza tra loro. Ciò consente di evidenziare pattern rilevanti come cambi di regime,

shock locali o dipendenze a lungo termine, migliorando sia la capacità predittiva sia l'interpretabilità della rete.

Consideriamo il vettore degli stati nascosti H :

$$H = [h_1, h_2, \dots, h_t]$$

Vengono calcolati i punteggi di similarità effettuando per lo stato corrente il prodotto scalare rispetto ai rimanenti stati e normalizzandolo rispetto alla dimensionalità:

$$e_{t,k} = \frac{h_t h_k^T}{\sqrt{d}}$$

I punteggi vengono normalizzati tramite Softmax per ottenere i pesi di attenzione:

$$\alpha_{t,k} = \frac{\exp(e_{t,k})}{\sum_j \exp(e_{t,j})}$$

La rappresentazione contestuale risultante è quindi la combinazione pesata degli stati nascosti :

$$c_t = \sum_k \alpha_{t,k} h_k$$

Nel modello implementato, l'output della Self-Attention viene poi ridotto lungo la dimensione temporale tramite un livello di Global Average Pooling, che produce una rappresentazione compatta successivamente proiettata dallo strato denso nella dimensione del vettore di previsione.

Capitolo 3 – Metodologia e set-up sperimentale

Il presente capitolo illustra il framework metodologico adottato per l'analisi e la preparazione degli input necessari, l'addestramento e la validazione dei modelli di Deep Learning proposti. La strategia sperimentale è stata disegnata per rispondere alle criticità identificate nello stato dell'arte, privilegiando la robustezza e la capacità di generalizzazione rispetto alla semplice massimizzazione delle performance su periodi favorevoli.

3.1 Metodologia

Una disamina della letteratura recente in ambito previsione dei prezzi energetici rivela una tendenza diffusa a limitare la fase di addestramento a finestre temporali ristrette, tipicamente comprese tra i 4 e i 6 mesi. Sebbene tale approccio permetta ai modelli di adattarsi rapidamente a specifiche condizioni stagionali ottenendo metriche di errore apparentemente ottime, esso comporta un rischio elevato di apprendere solo le peculiarità di un singolo periodo, fallendo nel catturare le dinamiche strutturali annuali.

In netta discontinuità con tale prassi, in questo lavoro si è scelto di estendere il Training Set a un periodo di circa 21 mesi. Questa scelta metodologica è intenzionale e volta non ad ottenere metriche artificialmente basse, bensì a costruire un modello robusto, capace di apprendere le dipendenze complesse di lungo periodo che caratterizzano il mercato elettrico.

3.1.1 Strategia di partizionamento del dataset

Coerentemente con questa impostazione, la prima fase del lavoro ha riguardato l'acquisizione delle variabili esogene oggetto di studio, con conseguente analisi esplorativa, preprocessing e pulizia dei dati (gestione outlier e normalizzazione). A valle di tale processo, il dataset aggregato è stato suddiviso cronologicamente in tre sotto-insiemi distinti, definiti come segue:

- **Training Set (21 Mesi)**: Dal 1° Gennaio 2022 al 20 Settembre 2023.
    - Obiettivo: Addestramento profondo del modello su quasi due cicli solari, includendo periodi di alta volatilità (crisi energetica 2022).
- **Validation Set (12 Mesi):** Dal 22 Settembre 2023 al 20 Settembre 2024.

    - Obiettivo: Ottimizzazione degli iperparametri e monitoraggio della convergenza per evitare l'overfitting.
- **Test Set (12 Mesi):** Dal 21 Settembre 2024 al 21 Settembre 2025.
    - Obiettivo: Valutazione finale delle performance (Out-of-Sample) su un intero anno diviso in 4 stagioni, per testare la capacità di generalizzazione su tutte le stagioni.

3.1.2 Strategia di ottimizzazione degli iperparametri

A seguito della divisione in set i dati sono stati normalizzati utilizzando appositi scaler e raggruppati in sequenze per essere processati dalle architetture. Al fine di garantire un confronto rigoroso tra le diverse architetture si è evitato l'utilizzo di configurazione standard degli iperparametri, che avrebbe potuto penalizzare o favorire alcuni modelli. Al contrario è stata condotta una fase di ottimizzazione degli iperparametri indipendente per ciascuna delle cinque architetture analizzate, differenziata inoltre per orizzonte previsionale. L' ottimizzazione è stata guidata perseguendo la minimizzazione dalle metriche di interesse attraverso il ciclo di ottimizzazione degli iperparametri.

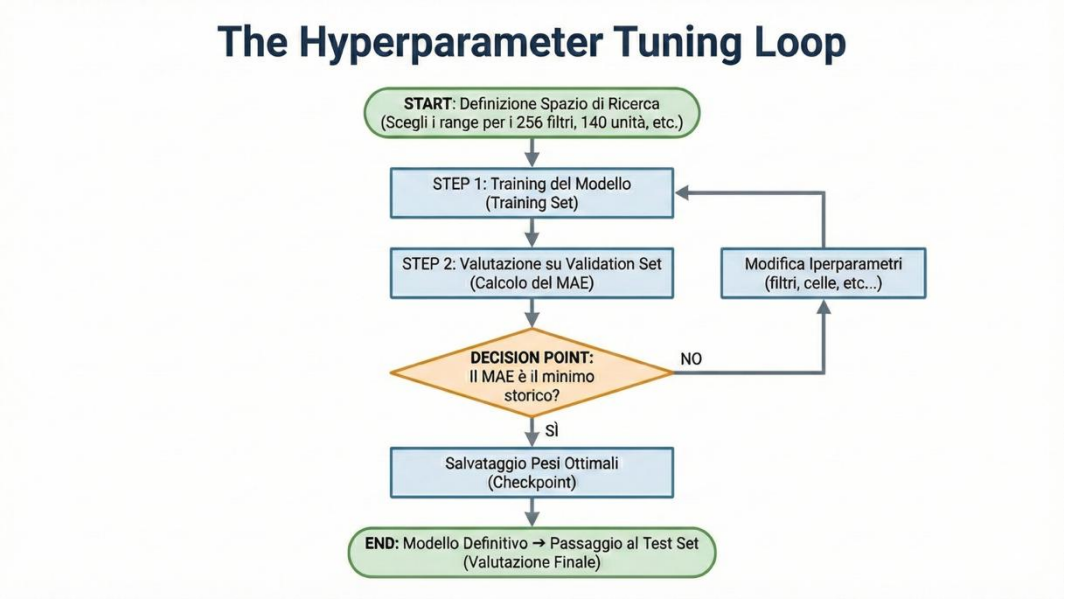

Figura 15 Ciclo di ottimizzazione degli iperparametri

Tale approccio trova gli iperparametri ottimali sul validation set per poi implementarli sul test set, assicurando così che il confronto finale avvenga tra modelli che stanno performando al massimo delle loro rispettive capacità teoriche.

3.1.3 Strategia di validazione

Il protocollo di validazione rappresenta uno degli elementi distintivi di questa ricerca. Per una valutazione diagnostica approfondita, l'anno di test è stato suddiviso in quattro sotto-periodi corrispondenti alle stagioni meteorologiche (Autunno, Inverno, Primavera, Estate).

Questa suddivisione è cruciale nel contesto del mercato elettrico italiano (in particolare per la Zona Centro-Sud), dove la variabilità della produzione da fonti rinnovabili altera strutturalmente la curva di offerta. Ad esempio, la primavera è spesso caratterizzata da un eccesso di offerta solare e bassa domanda, portando al fenomeno dei prezzi nulli mentre l'inverno è dominato dalla dinamica del gas naturale. L'analisi disaggregata per stagioni permette di effettuare un vero e proprio stress-test degli algoritmi, evidenziando non solo l'errore medio globale, ma identificando tempistiche e motivazioni del fallimento di una specifica architettura.

3.1.4 Contributo metodologico

Una delle maggiori barriere alla validazione scientifica nello stato dell'arte è la difficoltà di comparare risultati ottenuti su mercati, annualità e dataset eterogenei.

Il contributo chiave di questa tesi risiede nella definizione di un **framework di confronto standardizzato** a parità di tutte le condizioni a contorno. Le cinque architetture sono state valutate rispettando tre vincoli fondamentali:

1. **Stesso Dataset:** Tutti i modelli sono stati alimentati esclusivamente con i dati della Zona Centro-Sud/PUN, un'area selezionata per la sua nota complessità e volatilità.
2. **Stesso Periodo Temporale:** Identiche finestre di Training, Validation e Test per garantire che ogni modello fosse esposto alle medesime dinamiche.
3. **Stessa Metrica di Valutazione:** Uniformità nel calcolo degli errori (RMSE, MAE, MAPE).

Solo attraverso questo isolamento rigoroso delle variabili è possibile affermare con certezza scientifica se un'architettura offra un reale vantaggio computazionale rispetto a una struttura ricorrente semplice, depurando il risultato da fattori esterni o dalla selezione opportunistica dei dati.

3.2 Descrizione del dataset e analisi esplorativa

Il dataset utilizzato per tale analisi è stato costruito a partire da dati pubblici resi disponibili dal gestore dei mercati energetici GME [27] ,i dati si riferiscono al mercato del giorno prima MGP.

L' analisi si concentra sulla zona di mercato 'Centro-Sud'(CSUD), il dataset ha una granularità oraria e copre circa quattro anni di raccolta dati, contiene dati sui che vanno dal 1°gennaio 2022 al 21 settembre 2025, per un totale di 32.616 osservazioni. Per ogni ora del periodo analizzato, sono state estratte le seguenti variabili:

- **Generazione (MWh):** Rappresenta l'offerta totale di energia elettrica, espressa in MWh, prevista per quella specifica ora nella zona Centro-

Sud. Questo dato è un input fondamentale dell'asta, in quanto rappresenta la quantità di energia che può essere acquistata per soddisfare i consumi.

- **Prezzo Zonale (€/MWh):** È la variabile dipendente oggetto d'analisi. Rappresenta il prezzo di equilibrio dell'energia elettrica, espresso in €/MWh, risultato dall'incrocio tra la domanda e l'offerta in quella specifica ora per la zona Centro-Sud.
- **Acquisti (MWh):** rappresenta le quantità totali acquistate. È il punto di equilibrio, ovvero il volume totale di energia elettrica effettivamente comprato e venduto a quel prezzo zonale.

Nella costruzione del modello è stata presa in considerazione anche l'inclusione di variabili relative alla generazione fotovoltaica ed idroelettrica, poiché queste sono le più utilizzate tra le fonti rinnovabili nella zona C-SUD. Tuttavia, si è scelto di escludere tali variabili dal modello poiché l'obiettivo di questo studio è modellare il prezzo zonale, per condurre un'analisi robusta, infatti, sarebbe stato necessario utilizzare dati di generazione rinnovabile con la medesima granularità, relativi alla stessa zona di analisi, ma i dati di generazione oraria di facile reperibilità [1] sono disponibili solo a livello aggregato nazionale. La correlazione tra le due variabili sarebbe risultata spuria e metodologicamente errata. Per garantire la validità e la robustezza dell'analisi, si è quindi preferito limitare il modello alle sole variabili disponibili con la corretta e coerente granularità zonale, inoltre le architetture ibride permettono di superare la mancanza di variabili esplicite di generazione da rinnovabili, grazie alla capacità di mappare relazioni non lineari e variabili latenti, il modello è in grado di "dedurre" indirettamente il mix produttivo, analizzando l'interazione tra domanda, offerta e prezzo determinato.

In particolare, il modello apprende autonomamente il rapporto tra rinnovabili e non rinnovabili usate per la generazione: una combinazione di alta disponibilità (Generazione) e prezzi zonali bassi ,segnala implicitamente al modello una forte penetrazione di Fonti energetiche rinnovabili, le quali, avendo costi marginali prossimi allo zero, spostano la curva di offerta verso destra Pertanto, la rete LSTM è capace di ricostruire internamente lo stato del sistema energetico basandosi sui soli segnali di mercato disponibili con la

corretta granularità, garantendo una maggiore robustezza e validità statistica all'intero processo di forecasting.

Prima di procedere alla fase di modellazione, è stata condotta un'analisi esplorativa del prezzo zonale della zona Centro-Sud, con l'obiettivo di comprendere le principali dinamiche temporali, la stagionalità e la volatilità della serie. Questa analisi consente di evidenziare l'importanza di integrare all' interno del modello delle variabili di tipo esogeno e la forte non stazionarietà del mercato elettrico, motivando cosi la scelta di modelli non lineari per la previsione dei prezzi.

3.2.1 Andamento nel tempo

L' elemento preponderante del prezzo è la marcata ciclicità dei valori, legata all'andamento della domanda su base giornaliera, settimanale e stagionale.

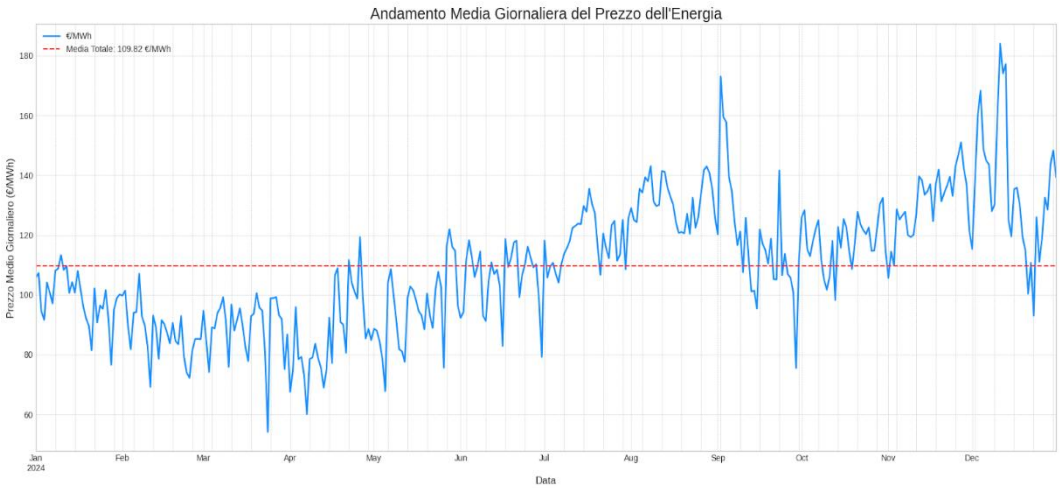

Figura 16 Andamento prezzo giornaliero dell' energia 2024

Per quanto riguarda l'andamento giornaliero, in un giorno feriale il prezzo tende ad aumentare nelle ore del mattino, con un primo picco tra le 8 e le 9, coincidente con l'avvio delle attività industriali. Segue un calo nella fascia pranzo (12-14), quando molte attività rallentano, per poi risalire e raggiungere

un massimo serale tra le 18 e le 20. In questa fascia, il rientro dei consumi domestici e il calo della produzione fotovoltaica richiedono l'impiego di centrali a maggior costo, come quelle a gas, che fanno inevitabilmente salire i prezzi. Dopo le 21 e fino al mattino seguente i valori si riducono, riflettendo consumi prevalentemente industriali a ciclo continuo.

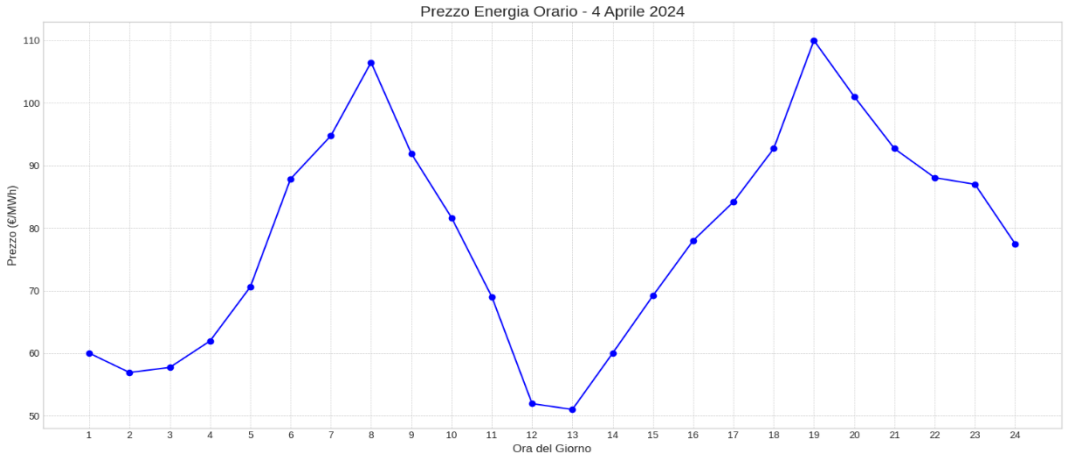

Figura 17 Andamento del prezzo orario 4 aprile

Nei giorni festivi lo scenario è diverso:

Analizzando per esempio una domenica il prezzo risulta essere alto e costante della fascia notturna (1-9) per poi decrescere, in generale il prezzo medio è generalmente più basso e con picchi meno marcati, dovuto a ritmi di vita differenti rispetto ai feriali.

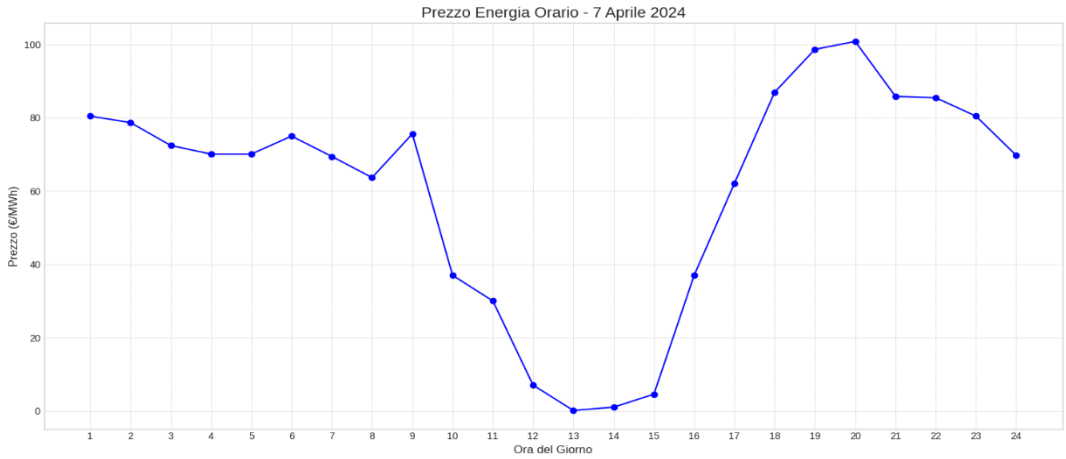

Figura 18 Andamento del prezzo orario 7 Aprile 2024

Oltre alla periodicità giornaliera si osserva inoltre una periodicità annuale nei prezzi dell'energia elettrica. In genere, i mesi invernali registrano valori più elevati, dovuti sia al minor numero di ore di luce, che incrementa il consumo per l'illuminazione artificiale, sia all'uso di sistemi di riscaldamento come pompe di calore o stufette elettriche.

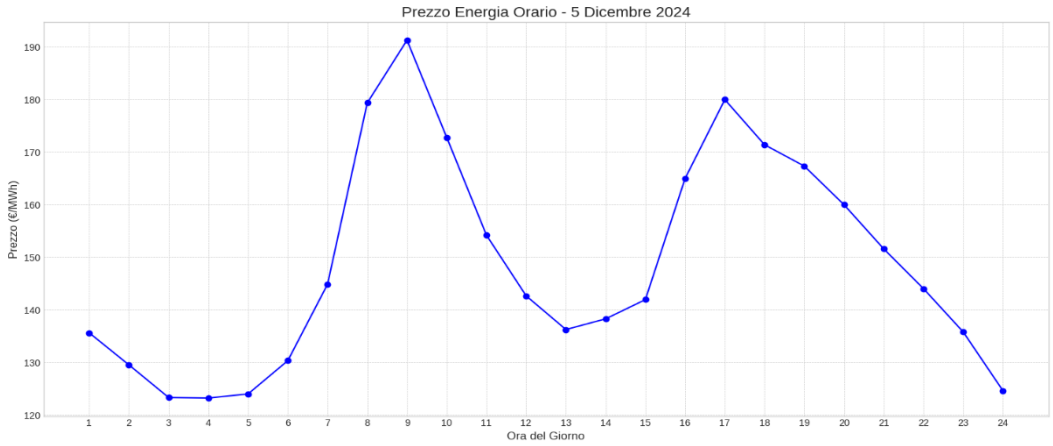

Figura 19 Andamento del prezzo orario 5 Dicembre 2024

Tuttavia, i picchi più alti si verificano spesso durante i mesi estivi, in particolare luglio e agosto, quando le temperature elevate rendono necessario l'uso massiccio dei condizionatori per raffreddare gli ambienti. Nei periodi primaverili e nei primi mesi autunnali, con giornate più lunghe e temperature moderate, la domanda di energia diminuisce, determinando prezzi generalmente più bassi.

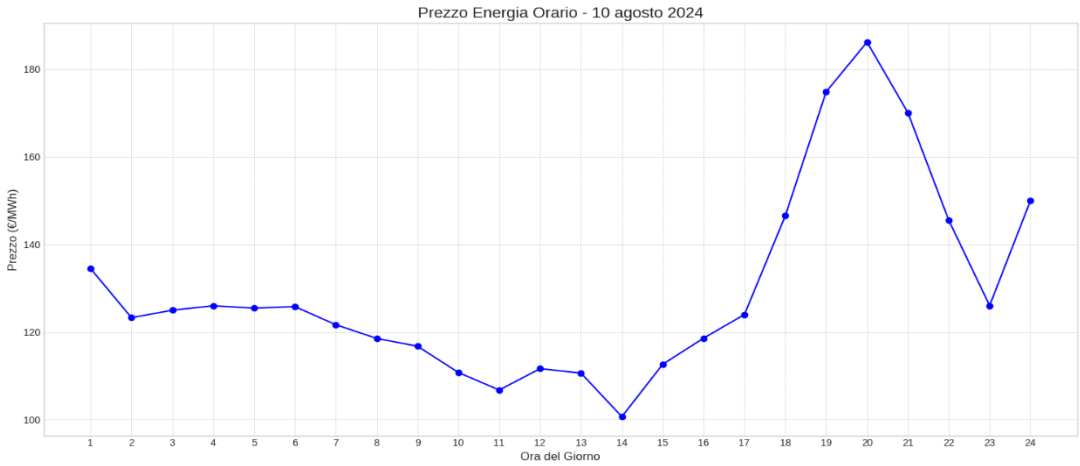

Figura 20 Andamento del prezzo orario 10 Agosto 2024

3.2.2 Scatter plot

Prima di procedere all' addestramento e alla valutazione dei modelli da implementare, viene condotta una analisi esplorativa per comprendere la dinamicità intrinseca del prezzo. La variabile di interesse per questa analisi è la fluttuazione oraria rispetto alla media giornaliera:

$$\Delta\% = \frac{Prezzo\ orario - Prezzo\ giornaliero}{Prezzo\ giornaliero} * 100$$

Il confronto non è puramente descrittivo, ma funzionale alla definizione del problema di apprendimento. La profonda non stazionarietà dei dati, ovvero il fatto che i regimi di mercato cambiano da una stagione all' altra, costituisce di fatto la sfida principale per gli algoritmi di previsione. Constatare l'esistenza di questi regimi giustifica l'abbandono dei modelli lineari a favore di architetture basate su RNN capaci di distinguere pattern locali eterogenei. In oltre, la differenza principale tra gennaio e luglio è la penetrazione fotovoltaica, indicativa dell' importanza di integrare il modello con variabili

esogene di tipo meteorologico, al fine di aumentarne l'efficacia predittiva di picchi e valli.

L' obiettivo di questo paragrafo è quindi quello di analizzare la differenza di comportamento tra due mesi diametralmente opposti, per osservare i risultati discussi all' interno delle teorie economiche sulle rinnovabili . È stata condotta quindi una analisi esplorativa dei dati usando lo scatter plot per osservare visivamente la distribuzione dei dati e identificare gli outlier. Il dataset utilizzato per tale analisi è stato ottenuto a partire da 3 anni di osservazione (2022, 2023, 2024), aggregando i giorni corrispondenti ai mesi in esame. Vengono pertanto prodotti due grafici: uno per gennaio e uno per luglio, questi mappano ogni ora del campione stagionale come un singolo punto:

- **Asse X (Giorno aggregato):** L'asse orizzontale rappresenta il tempo. Per aggregare i tre anni di dati in un'unica vista stagionale, i giorni del mese in questione sono stati 'impilati' su un unico asse da 0 a 90 giorni.
- **Asse Y (Fluttuazione della media giornaliera %):** "L'asse verticale rappresenta lo scostamento percentuale di quell'ora rispetto alla media del giorno. Un punto a +20% indica un prezzo del 20% superiore alla media di quel giorno; un punto a -10% indica un prezzo del 10% inferiore.

Di seguito i grafici per i mesi di gennaio e luglio:

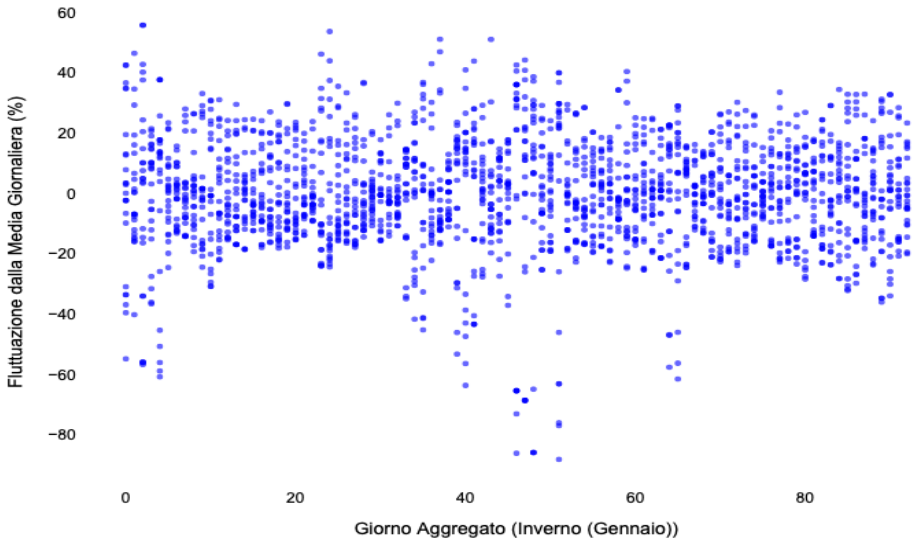

Figura 21 Scatter plot aggregato gennaio

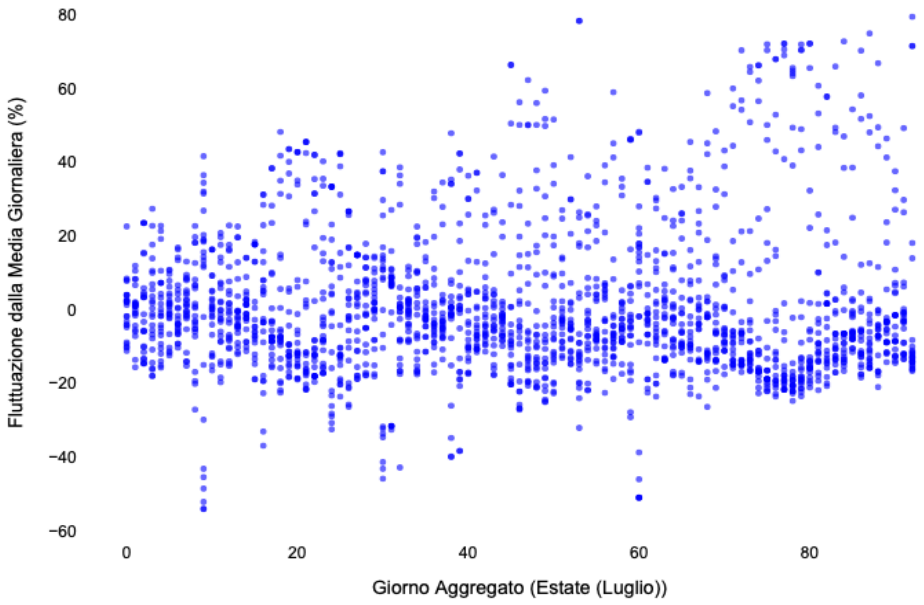

Figura 22 Scatter plot aggregato Luglio

Confrontando visivamente i risultati sono stati osservati i valori record di fluttuazione per i due periodi:

- **Gennaio:** I mesi invernali mostrano il crollo di prezzo più significativo, con un outlier che raggiunge **-88.22%** rispetto alla media giornaliera. Il picco positivo massimo è più contenuto, attestandosi a **+55.71%**.
- **Estate :** I mesi estivi, al contrario, mostrano il picco positivo più elevato, raggiungendo **+79.30%**. Il crollo massimo è notevole, ma meno profondo di quello invernale (**-54.13%**).

L' analisi dei soli valori massimi e minimi risulta però essere incompleta, infatti, quello che emerge è che esistono dispersioni diverse tra gennaio e luglio.

- **Gennaio:** Nonostante il record negativo (-88.22%), la nuvola di punti appare visivamente più concentrata. Questo suggerisce che il mercato invernale è caratterizzato da una relativa stabilità, interrotta però da eventi shock rari .

- **Luglio:** Al contrario, la nuvola di punti di luglio, pur non avendo lo stesso record negativo suggerisce una maggiore dispersione, indicando una volatilità maggiore, spesso collegata a fluttuazioni positive.

In sintesi, da un'analisi preliminare lo scatter plot suggerisce due profili di rischio diversi: gennaio è esposto a rari Shock di crollo, mentre luglio è caratterizzato da una volatilità di fondo più costante.

3.2.3 Box plot

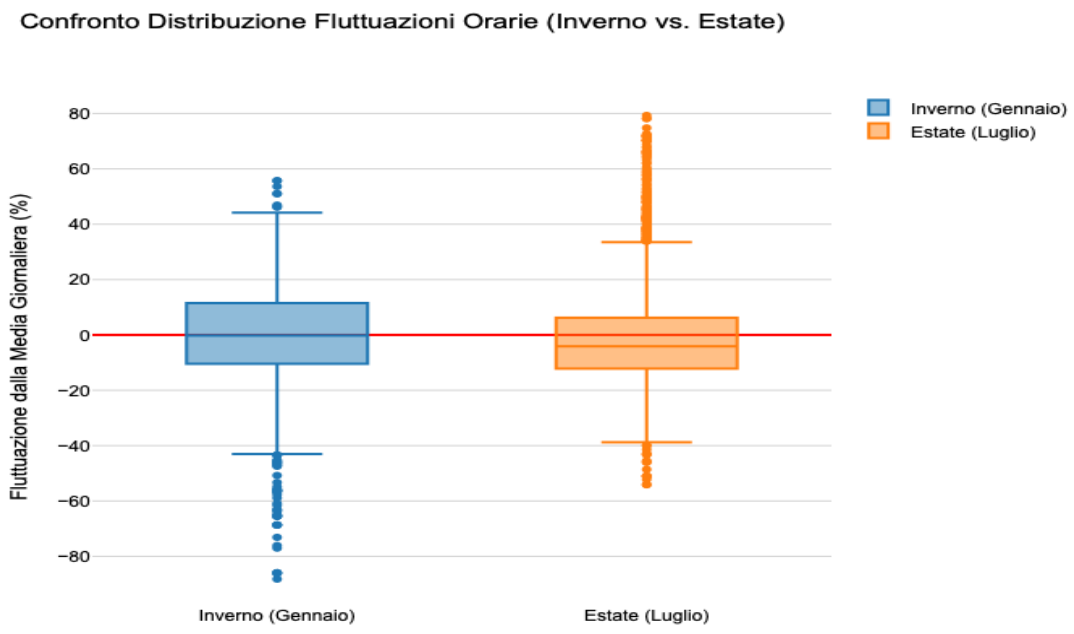

Figura 23 Confronto Distribuzione delle Fluttuazioni Orarie

Dall'esame del Box Plot emergono due aspetti fondamentali per la nostra analisi, infatti troviamo :

- **Mediana estiva negativa**: il posizionamento della mediana nel mese invernale (linea orizzontale all' interno del Box) è quasi allineato con la media giornaliera (-2,06%),mentre nel mese estivo è rilevato un disallineamento con la mediana che si colloca al di sotto dello zero (circa -4,14%) evidenziando che per oltre il 50% delle osservazioni il valore orario è inferiore alla media giornaliera.
- **Distribuzione asimmetrica degli outlier** : Le due stagioni mostrano inoltre dei comportamenti opposti riguardo ai valori estremi. Infatti, la distribuzione invernale presenta una marcata asimmetria negativa con gli outlier concentrati verso il basso,mentre al contrario quella estiva presenta numerose fluttuazioni verso l'alto che bilanciano la mediana negativa analizzata in precedenza.

3.2.4 Mappa di Densità

Per superare i limiti dello scatter plot e quantificare con precisione la concentrazione degli eventi, è stato implementato un algoritmo di Mappatura di Densità tramite (Python *Plotly Histogram2dContour*). Questo metodo effettua un conteggio discreto ed esatto delle occorrenze.

Lo spazio di fase (Tempo vs Fluttuazione) è stato discretizzato in una matrice **30x30**, definita dai seguenti parametri estratti direttamente dal codice di elaborazione:

- **Asse Y (Ampiezza della Volatilità):** Per rendere confrontabili i diversi periodi stagionali, il range delle fluttuazioni è stato standardizzato in un intervallo totale di 120 punti percentuali (da -60% a +60%). Suddividendo tale estensione per i 30 intervalli della griglia, si ottiene una risoluzione costante di **4% per ogni bin**.
- **Asse X (Aggregazione Temporale):** L'asse temporale copre l'intera stagione trimestrale (90 giorni), per un totale di 2160 ore. Dividendo questo orizzonte per i 30 intervalli della griglia, si ottiene una risoluzione temporale di **72 ore per bin**. Ogni colonna della mappa aggrega pertanto, i dati relativi a tre giorni consecutivi.

Per ognuna di queste celle (intersezioni tra range di prezzo e intervallo temporale), vengono contati i punti effettivi. La visualizzazione cromatica facilita l'interpretazione: le tonalità tendenti al giallo indicano gli eventi più frequenti (alta densità), mentre quelle tendenti al blu rappresentano eventi rari o assenti.

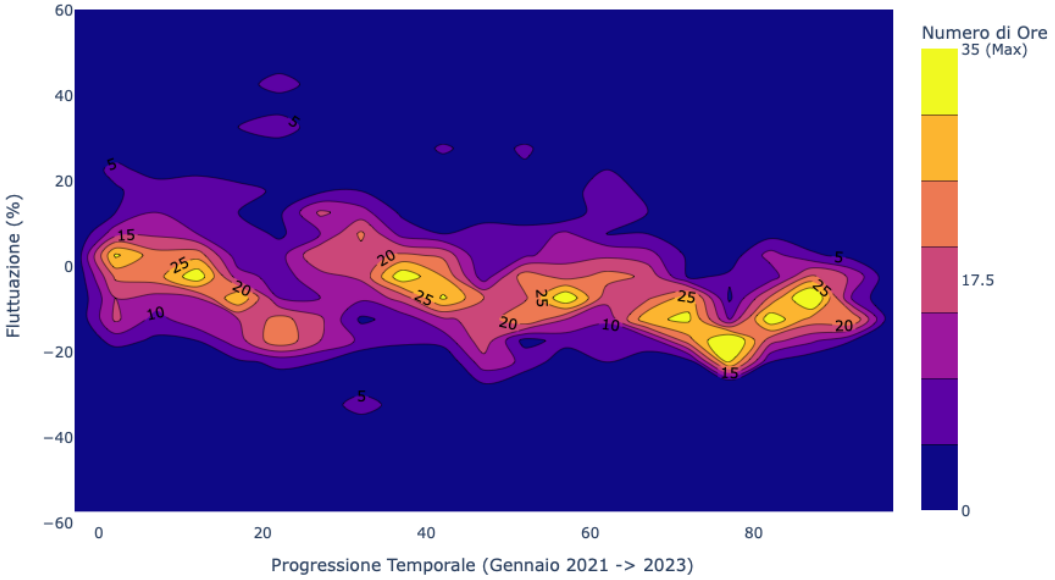

Figura 24 Mappa di Densità aggregata Luglio

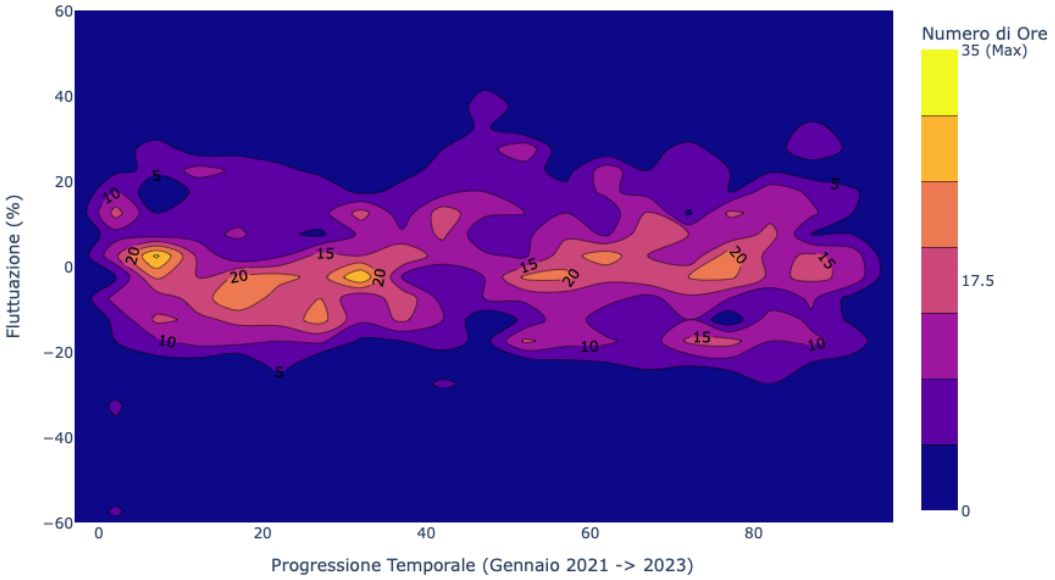

Figura 25 Mappa di Densità aggregata Gennaio

Dall'ispezione visiva delle mappe emerge una differenza strutturale nel comportamento del mercato tra le due stagioni. Mentre a gennaio la densità appare distribuita in modo più simmetrico attorno allo zero, a luglio si nota una marcata depressione dei valori, con una concentrazione di eventi spostata verso il quadrante negativo. Per validare statisticamente questa osservazione, i dati sono stati estratti e organizzati in due tabelle focalizzate sul range core di fluttuazione [-32;0] e [0;+32]. I valori percentuali riportati in tabella rappresentano la quota di tempo in cui il mercato si è trovato in un determinato intervallo di volatilità. Questa scomposizione permette di distinguere nettamente il comportamento del prezzo quando si trova sopra o sotto la sua media giornaliera:

Intervallo di Fluttuazione	Gennaio	Luglio
-[32-28]	**0,95%**	**0,46%**
-[28-24]	**1,72%**	**0,73%**
-[24-20]	**2,54%**	**3,83%**
-[20-16]	**5,89%**	**7,93%**
-[16-12]	**8,42%**	**11,94%**
-[12-8]	**7,38%**	**12,08%**
-[8-4]	**8,78%**	**12,76%**
-[4-0]	**12,72%**	**12,22%**

Tabella 2 Tabella delle occorrenze negative della mappa di densità

Nella prima tabella possiamo notare che a luglio, il mercato manifesta uno squilibrio netto. Il **61,95%** delle ore dell'intervallo in esame è confinato al di

sotto della media giornaliera, con una differenza di ben **14 punti percentuali** rispetto a gennaio. In particolare, sommando i bin tra -8% e -16%, si nota come quasi il **37%** dell'intero trimestre sia caratterizzato da depressioni sistemiche.

Intervallo di fluttuazione	Gennaio	Luglio
+[32-28]	2,26%	1,23%
+[28-24]	3,26%	1,69%
+[24-20]	4,12%	1,78%
+[20-16]	5,07%	2,87%
+[16-12]	6,56%	3,37%
+[12-8]	7,02%	3,69%
+[8-4]	7,61%	6,29%
+[4-0]	11,05%	9,43%

Tabella 3 Tabella delle occorrenze positive della mappa di densità

Nella seconda tabella invece possiamo notare che gennaio mostra una distribuzione quasi perfettamente simmetrica attorno alla media (47,95% sotto vs 46,95% sopra). Mentre luglio solo il 30,35% si trova al disotto della media, contro il 61,95 % delle fluttuazioni negative.

Di conseguenza possiamo dedurre che per **gennaio** la volatilità è priva di nuclei di condensazione dominanti che si discostano dalla media giornaliera. Questo pattern suggerisce un mercato guidato da fattori aleatori che non generano configurazioni strutturali e anomale durante il giorno.

Per **luglio** la mappa estiva rivela una struttura di gran lunga diversa, dominata da due fenomeni ritroviamo nelle teorie economiche sulle rinnovabili [28]:

- **Depressione sistematica:** La quasi totalità della densità si trova nella parte inferiore del grafico ovvero quella che rappresenta fluttuazioni negative rispetto alla media giornaliera; infatti, si osservano 5 aree con alta densità (più di 30 eventi ciascuna) posizionate in una fascia di fluttuazione moderata (4 - 12%). Ciò mostra visivamente come l'immissione di energia solare deprima sistematicamente i prezzi al di sotto della media giornaliera.
- **Effetto cannibalizzazione :** Il dato più rilevante è la formazione di un cluster ad altissima densità (zona giallo brillante) che conta oltre **30 eventi** concentrati in una singola finestra temporale, a un livello di prezzo del **-20%**. Questa valle nel grafico non è casuale, ma rappresenta momenti di sovraproduzione, probabilmente nelle ore di massimo irraggiamento. In queste ore, il mercato non è riuscito ad assorbire l'energia prodotta, causando un crollo verticale dei prezzi ben più profondo della normale fluttuazione di mercato.

In Conclusione, mentre gennaio è caratterizzato da outlier negativi e da una volatilità casuale e distribuita ,generata probabilmente dalla domanda o da fluttuazioni del prezzo del gas, l'estate presenta fluttuazioni negative sistematiche concentrate al di sotto della media giornaliera, ma con outlier positivi. Il modello predittivo dovrebbe quindi essere calibrato per anticipare specificamente questi eventi di cannibalizzazione (-20%) che costituiscono la firma energetica del fotovoltaico. Tale comportamento giustifica la necessità di integrare nel modello predittivo variabili esogene come le previsioni metereologiche. La loro assenza, infatti, rischierebbe di invalidare la capacità del modello di anticipare i picchi strutturali generati dalle dinamiche di *ramping* serale.

3.3 Preprocessing dei dati

La qualità del modello dipende direttamente dai dati in input, per questa motivazione il preprocessing dei dati risulta essere di grande rilevanza. I dati grezzi, infatti, non sono direttamente utilizzabili dalla rete neurale per due motivi principali:

1. **Scala dei Valori:** I dati hanno scale molto diverse che possono saturare le funzioni di attivazione della rete, impedendole di apprendere.
2. **Natura Sequenziale:** Un modello LSTM richiede che i dati siano formattati in sequenze per apprendere le dipendenze dal passato e prevedere il futuro.

Questa sezione descrive i tre passaggi chiave eseguiti: la divisione cronologica del dataset, la normalizzazione e la creazione di sequenze di input/output.

3.3.1 Divisione Cronologica del Dataset

Avendo a disposizione circa 4 anni (dal 1° gennaio 2022 al 21 settembre 2025), è stata adottata una divisione che rappresenta la metodologia più robusta per garantire un modello affidabile per tutte le stagioni,utilizzando la seguente suddivisione:

- **Training Set (circa 2 anni: 2022-2023):** Questo set parte dal 1° gennaio 2022 e arriva al 21 settembre 2023, includendo anche la crisi energetica del 2022. Quest' ultimo è utilizzato per addestrare il modello in modo tale che apprenda i pattern fondamentali.

- **Validation Set (1 anno: 2023-2024):** Questo set parte dal 22 settembre 2023 e arriva al 20 settembre 2024. Usarlo per la validazione ci permette di scegliere gli iperparametri che funzionano per tutte le stagioni e non per una stagione specifica. Gli indicatori calcolati con questo metodo tengono conto della capacità del modello di generalizzare e di imparare le relazioni stagionali a discapito però delle performance, che essendo

calcolate sull' intero anno tendono a crescere rispetto ad una ottimizzazione specifica su una singola stagione.

- **Test set:** Questo set è utilizzato solo per valutare le performance finali del modello andando a simulare il suo comportamento su dati sconosciuti e osservando quindi la sua capacità di generalizzazione. In particolare, l'anno che va dal 21 settembre 2024 al 21 settembre 2025 è stato diviso in 4 stagioni per testare il modello rispettivamente ad ognuna: **Autunno:** 2.160 ore (corrispondenti a 90 giorni); **Inverno:** 2.160 ore (corrispondenti a 90 giorni); **Primavera:** 2.208 ore (corrispondenti a 92 giorni); Estate**:** 2.232 ore (corrispondenti a 93 giorni).

3.3.2 Protocollo di Addestramento Dinamico

Per la valutazione finale sul test set non si è proceduto ad un approccio statico, ma ad un approccio dinamico che va ad incorporare le informazioni più recenti per la previsione. Questo prevede una strategia che accresce il set di addestramento dopo ogni previsione stagionale permettendo al modello di apprendere dai dati più recenti e adattarsi ai cambiamenti stagionali.

Il punto di inizio del test (*Start Point*) è stato individuato nel dataset all'indice posizionale 23.856, che corrisponde cronologicamente all'inizio della stagione autunnale (21 settembre del 2024).

Il processo si svolge in quattro passaggi sequenziali:

1. **(Previsione Autunno):** Il modello viene addestrato su tutto lo storico disponibile fino a quel momento e utilizzato per prevedere i dati dell'Autunno.
2. **(Previsione Inverno):** Il set di addestramento viene aggiornato includendo i dati reali dell'Autunno e viene quindi addestrato nuovamente con questa maggiore conoscenza per prevedere l'Inverno.
3. **(Previsione Primavera):** Si effettua un ulteriore aggiornamento, aggiungendo al set di addestramento anche i dati dell'Inverno ri-addestrandolo per la previsione della primavera.

4. **(Previsione Estate):** Infine, si integrano i dati della Primavera nel set di addestramento. Il modello, ora completo di tutte le informazioni stagionali precedenti, viene addestrato nuovamente per prevedere l'Estate.

Questa metodologia garantisce che ogni previsione sia generata utilizzando la massima quantità di informazione storica disponibile al momento della stima, simulando fedelmente l'operatività di un sistema di previsione in un contesto reale.

3.3.2 Normalizzazione

Dato che i modelli LSTM sono sensibili alla scala degli input e che il nostro Training Set contiene valori anomali estremi come picchi e valli, la scelta dello scaler è critica, di seguito gli scaler considerati :

- **MinMaxScaler**: Si è esclusa questa tecnica di normalizzazione poiché esso opera una trasformazione lineare che normalizza i dati in un intervallo predefinito, basandosi esclusivamente sul valore minimo assoluto $Xmin$ e sul massimo assoluto $Xmax$ presenti nel dataset:

$$x_{\text{scaled}} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

- **StandardScaler** : Questa tecnica utilizza la media e la deviazione standard. Queste sono metriche sensibili agli outlier, che avrebbero potuto distorcere la distribuzione dei dati:

$$x_{\text{scaled}} = \frac{x - \mu}{\sigma}$$

- **RobustScaler** : Questa tecnica utilizza statistiche immuni agli outlier: la Mediana *Q2*, il primo quartile *Q1* e il terzo quartile *Q3*, del training set:

$$x_{\text{scaled}} = \frac{x - Q_2}{Q_3 - Q_1}$$

In questo modo, i dati vengono scalati efficacemente, mentre l'outlier viene semplicemente mappato come un valore molto alto, senza però rovinare la scala di tutti gli altri punti.

Criterio di Applicazione dello Scaler

Lo scaler è stato costruito utilizzando unicamente il Training Set per poi usarlo per scalare tutti i set (Training, Validation e Test). Operare diversamente avrebbe compromesso la validità dell'esperimento, poiché le informazioni provenienti dalla distribuzione del Validation e Test Set sarebbero trapelate nel processo di addestramento. Questo avrebbe fornito al modello una conoscenza a priori dei dati futuri, portando a stime di performance irrealisticamente ottimistiche e invalidando l' esperimento.

3.3.3 Creazione delle sequenze

Una volta normalizzati, i dati strutturati come una serie temporale non possono ancora essere elaborati da una LSTM. È necessario quindi trasformare la serie in un problema di apprendimento supervisionato. La funzione utilizzata si occupa di "appiattire" una sequenza di dati passati in un singolo vettore di features e associarlo a uno o più output.

Essendo interessati a predire valori orari e giornalieri sono state realizzati 2 sequenze differenti, la prima utilizza una finestra mobile di 72 osservazioni orarie, (corrispondenti a 3 giorni) sulle 3 variabili per predire un solo valore

orario, la seconda utilizza 168 osservazioni orarie (corrispondenti a una settimana), sempre sulle 3 variabili, ma per predire le 24 ore successive.

Di seguito i passaggi logici per la prima sequenza (ragionamento analogo per la seconda):

1. **Creazione degli Input (X):** Per ogni campione vengono utilizzate le 72 osservazioni passate per le 3 feature. Il risultato è un singolo vettore di input di 72 * 3 = 216 features, che crea la sequenza in ingresso: [*var1(t-72), var2(t-72), var3(t-72), ..., var1(t-1), var2(t-1), var3(t-1)]*
2. **Creazione degli Output (y):** Aggiunge le colonne per il timestep corrente (t). Dato n_out=1, aggiunge le 3 colonne: var1(t), var2(t), var3(t).
3. **Pulizia degli Output:** L'obiettivo del modello è predire solo il prezzo (€/MWh), non gli acquisti e la generazione futura, il codice quindi rimuove le altre colonne di output non necessarie.
4. **Divisione Finale:** Il DataFrame risultante viene infine diviso per l' addestramento in:
    - **Train_X / Validation_X:** Matrici contenenti i vettori di input.
    - **Train_Y / Validation_Y:** Vettori contenenti il valore target.

Infine l'architettura LSTM richiede un input 3D con la forma [campioni, passi temporali, features]. Il nostro train_X (con forma [campioni, 216]) è 2D. Pertanto, un ultimo passaggio consiste nel **rimodellare** questo vettore appiattito per restituirgli la sua struttura temporale originale, trasformando la forma da [campioni, 216] a [campioni, 72, 3], l'input finale richiesto dal modello.

3.4 Architetture dei modelli analizzati

Di seguito sono riportati i modelli utilizzati nello studio, ciascuno dei quali integra le tecniche descritte nei paragrafi precedenti:

- **LSTM**
- **BiLSTM**
- **CNN–LSTM**
- **CNN–BiLSTM**
- **CNN–BiLSTM–Attention**

Il modello più complesso (CNN–BiLSTM–ATT), è ispirato all'architettura proposta da Z. Wang et al. [13] ed è caratterizzato dall'integrazione sequenziale di tre moduli: una rete convoluzionale per l'estrazione delle feature locali, un modulo ricorrente bidirezionale per la modellazione delle dipendenze temporali e un meccanismo di self-attention per la ponderazione contestuale delle informazioni estratte. L'ingresso del modello è costituito da una finestra temporale multivariata, l'uscita in un vettore di previsione multi-step.
Il flusso dei dati attraverso l'architettura segue lo schema seguente:

1. **Input Layer:** acquisizione della sequenza grezza.
2. **Blocco CNN:** estrazione di pattern locali e riduzione del rumore tramite convoluzione e operazione di pooling.
3. **BiLSTM:** modellazione della dinamica temporale in entrambe le direzioni.
4. **Self-Attention e Global Average Pooling:** assegnazione di pesi agli stati ricorrenti e generazione di una rappresentazione compatta.
5. **Dense Layer:** regressione finale sugli orizzonti di previsione.

Il primo modulo ,è uno strato convoluzionale seguito da MaxPooling. La CNN agisce con due obiettivi principali:

- **Filtrare il rumore**, evidenziando pattern locali robusti.

- **Ridurre la dimensionalità**, grazie al pooling che accorcia la sequenza e diminuisce il costo computazionale dei moduli successivi.

La sequenza risultante è una mappa di feature più compatta, che funge da rappresentazione di alto livello dei dati originali, successivamente viene applicata una rete BiLSTM, che elabora la sequenza nelle due direzioni temporali. Questo passaggio produce, per ogni istante temporale, una rappresentazione arricchita sia del passato sia del futuro, mantenendo la struttura sequenziale. L'output della BiLSTM, la sequenza di stati nascosti, che preserva la temporalità è quindi elaborata da un meccanismo di attenzione. Il meccanismo di self-attention infatti, opera come un filtro adattivo: confronta gli stati provenienti dalla BiLSTM e attribuisce a ciascuno un peso, evidenziando le porzioni della sequenza più informative per la previsione. Questo consente al modello di:

- isolare i segnali determinanti,
- attenuare il rumore residuo,
- identificare dipendenze globali che non emergono dalla convoluzione locale.

La rappresentazione pesata viene infine condensata tramite Global Average Pooling, che produce un vettore compatto da passare allo strato finale di regressione.

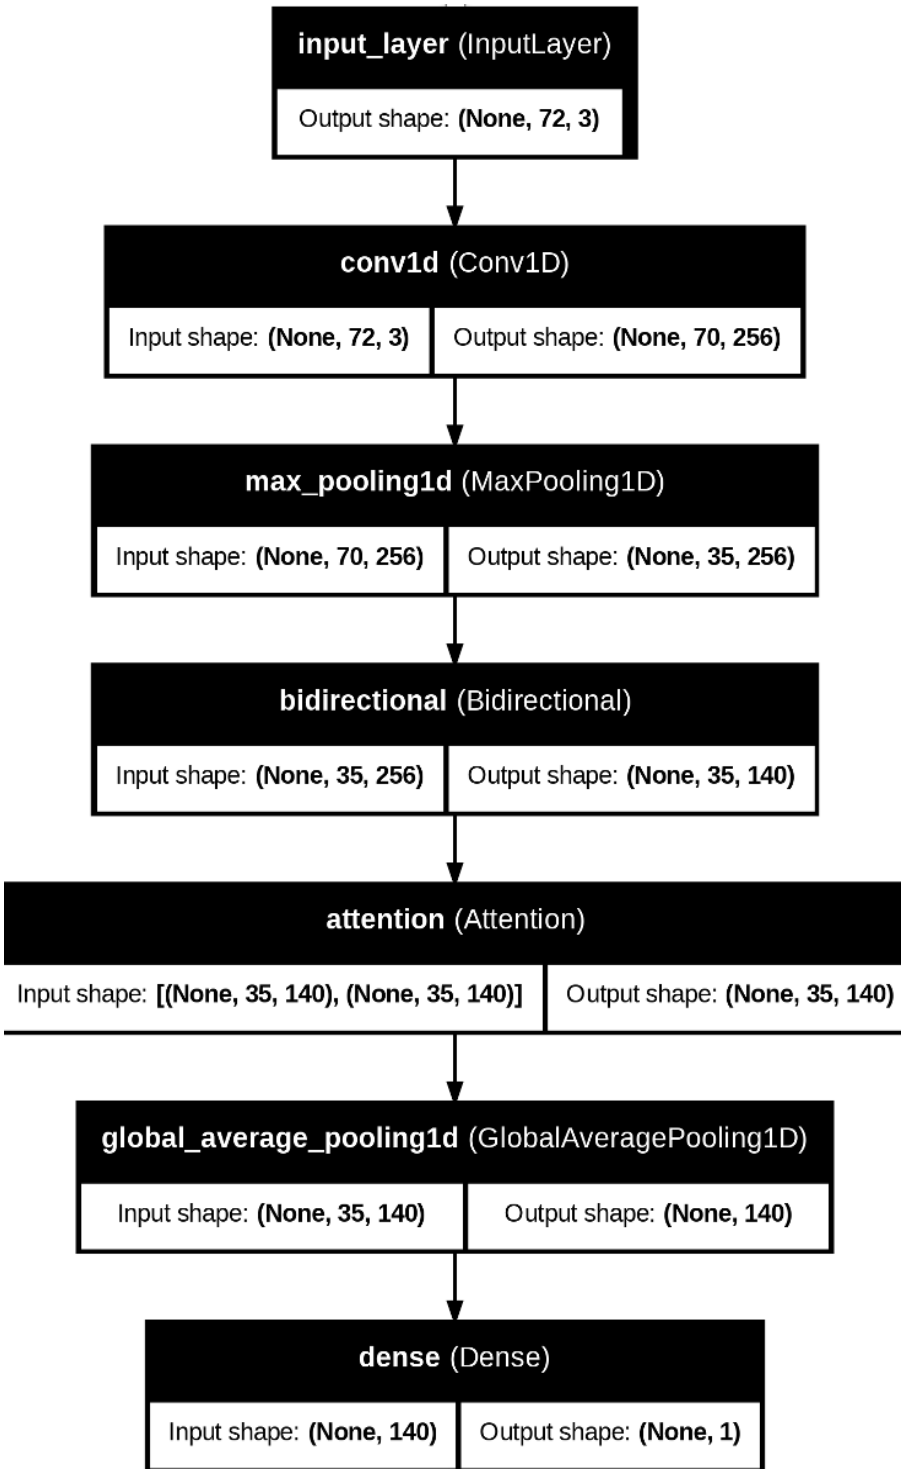

Figura 26 Rappresentazione architettura CNN-Bi-LSTM -ATT

3.5 Metriche di Valutazione

Per valutare e confrontare le performance dei diversi modelli di previsione sviluppati in questa tesi, è essenziale definire un set di metriche di errore standard. Questo paragrafo si descrivono le tre metriche utilizzate: MAE (Mean Absolute Error), RMSE (Root Mean Squared Error) e MAPE (Mean Absolute Percentage Error).

3.5.1 MAE

Il **Mean Absolute Error (MAE)** rappresenta l'errore medio assoluto delle previsioni. Misura la differenza tra la media tra i valori previsti e dei valori reali in modulo.

Il suo grande vantaggio risiede nella sua diretta interpretabilità: il risultato è espresso nella stessa unità di misura dei dati (€/MWh). La formula per il MAE è:

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - y_i^*|$$

3.5.2 RMSE

L'RMSE (Root Mean Squared Error) è la radice quadrata della media degli errori elevati al quadrato, l'RMSE ha una caratteristica distintiva, ovvero quella di penalizzare gli errori più grandi in modo più che proporzionale. Questo avviene perché ogni errore viene prima elevato al quadrato. Di conseguenza questa metrica è quindi particolarmente utile per capire se il modello produce saltuariamente previsioni folli con errori molto elevati. Un

RMSE significativamente più alto del MAE indica la presenza di una maggiore varianza negli errori. La formula dell'RMSE è:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - y_i^*)^2}$$

3.5.3 MAPE

Il MAPE (Mean Absolute Percentage Error) misura l'errore medio in termini percentuali. È una metrica quindi che non dipende dall'unità di misura dei dati, e ciò la rende utile per confrontare l'accuratezza di previsioni su serie con scale diverse.

Rappresenta, in media, la deviazione percentuale delle previsioni rispetto ai valori reali. La formula per il MAPE è:

$$MAPE = \frac{100}{n}\sum_{i=1}^{n}\frac{(y_i - y_i^*)}{y_i}$$

3.6 Strumenti e ambiente di sviluppo

La creazione e la validazione dei modelli presentati ha richiesto uno specifico set di hardware e software, che vengono di seguito elencati per garantire la riproducibilità degli esperimenti e l'accuratezza dell'analisi. Di seguito le tecnologie e le librerie utilizzate. Per velocizzare l'attività di calcolo, che in caso contrario sarebbe risultata particolarmente onerosa, l'attività sperimentale è stata condotta all' interno dell'ambiente cloud Google Colab, configurato per utilizzare GPU NVIDIA Tesla T4. L' utilizzo è stato determinante per ridurre

i tempi di training richiesti dai modelli. Il codice è stato sviluppato interamente in linguaggio Python, di seguito si descrivono le principali librerie integrate nel progetto e la loro funzione specifica.

3.6.1 Gestione e Manipolazione dei Dati

Pandas: Utilizzata per il dataset (file CSV), la gestione delle serie storiche e il calcolo di indici temporali per il confronto tra le previsioni e i valori reali. La libreria è stata fondamentale per l'allineamento dei dati di prezzo e la gestione delle date (datetime).

.

3.6.2 Normalizzazione e Metriche

Scikit-Learn: Da questa libreria è stato importato il modulo RobustScaler per la normalizzazione dei dati e per il calcolo delle metriche di valutazione dell'errore come MSE e RMSE, per il mape invece è stata creata una funzione apposita.

3.6.3 Implementazione delle Architetture

TensorFlow & Keras: L'implementazione delle architetture è stata realizzata utilizzando il framework TensorFlow tramite l'API di alto livello Keras.

Sono stati utilizzati modelli di tipo Sequential e Functional API per assemblare strati complessi (LSTM, Bidirectional, Conv1D, Dense).

La libreria ha permesso inoltre la visualizzazione schematica delle architetture tramite le utility plot_model(con supporto di pydot e graphviz), garantendo una verifica visiva della topologia delle reti.

3.6.4 Visualizzazione e Analisi dei Risultati

Plotly: Per la visualizzazione delle variabili oggetto di analisi e per i risultati, si è scelto di utilizzare Plotly,questo strumento ha permesso la visualizzazione dei grafici presenti nell' elaborato. Inoltre la libreria Plotly Graph Objects ha permesso la generazione di grafici interattivi, essenziali per l'analisi di serie storiche volatili come i prezzi dell'energia. Grazie alle funzionalità di zoom dinamico e hovering, è stato possibile ispezionare nel dettaglio il comportamento dei modelli in corrispondenza dei picchi di prezzo e valutare la fedeltà della previsione su finestre temporali specifiche.

Capitolo 4 – Risultati e analisi comparativa

In questo capitolo viene presentata la fase di addestramento, ottimizzazione e comparazione dei modelli di previsione implementati. In particolare, vengono discusse le scelte relative agli iperparametri, le architetture e le metriche di valutazione, analizzando l'impatto sulle performance nei due orizzonti temporali considerati.

4.1 Training e ottimizzazione dei modelli

In questo capitolo vengono descritte le configurazioni adottate per l'addestramento delle diverse architetture sul Validation set . L' obiettivo è quello di illustrare le scelte degli iperparametri effettuate in fase di addestramento dei modelli e analizzare come esse influenzano l'apprendimento nei due orizzonti temporali attraverso lo studio delle funzioni di perdita, le scelte implementative derivano dalla necessità di ottimizzare la metrica di interesse. L'algoritmo di ottimizzazione utilizzato in fase di addestramento è stato l'ADAM (Adaptive Moment Estimation), la sua scelta rispetto al classico SGD (Stochastic Gradient Descent) deriva dalla capacità di usare un learning rate adattivo per ogni parametro individualmente, favorendo una convergenza più rapida. Come funzione di perdita dell'errore è stato usato l'errore medio assoluto MAE, questo ci assicura che il modello venga ottimizzato sulla stessa metrica di confronto finale.

4.1.1 Tuning degli iperparametri

La scelta degli iperparametri finali è stata determinata da prove empiriche, osservando se aumentare o diminuire un certo set di iperparametri modificava l'errore assoluto medio e la relativa funzione di perdita. In conclusione alle

prove effettuate è stata selezionata la combinazione che minimizzava il MAE per la specifica architettura, dì seguito i valori degli iperparametri finali:

- **Batch Size:** Fissato a **64**. Questo valore rappresenta un buon Trade-off computazionale, offrendo una stima del gradiente sufficientemente stabile, ma senza saturare la memoria della GPU T4 che è stata utilizzata.

- **Gestione delle Epoche:** Per le architetture standard (LSTM, Bi-LSTM, CNN-LSTM, CNN-BiLSTM), il numero di epoche è stato fissato a **30**, soglia che ha dimostrato di garantire la convergenza senza incorrere in overfitting innalzato a **50** per le architetture con meccanismo di attenzione. Infatti introdurre un ulteriore livello di complessità ha reso necessario un tempo di addestramento prolungato per stabilizzare la funzione di perdita.

4.1.2 Dimensionalità delle architetture

In base agli schemi architetturali implementati, la capacità dei modelli è stata dimensionata come segue:

- **LSTM :** Configurato con uno strato nascosto formato da **100** neuroni, seguito da un output layer.

- **Bi-LSTM:** Utilizza uno strato bidirezionale che raddoppia la capacità di elaborazione, l'output shape di **140 unità** indica l'elaborazione parallela della sequenza, 70 *forward e 70 backward.*

- **Modelli ibridi:** La componente convoluzionale **1D** è stata impostata con **256 filtri** per l'estrazione delle feature locali, kernel size pari a **3** con funzione di attivazione RELU e seguita da Max Pooling con pooling size pari a **2**, mentre la rete a valle mantiene la dimensione di **100 unità** (LSTM) o **140 unità** (BiLSTM). L' attention invece non aggiunge parametri allenabili.

- **Input/Output Shape:**
    - Previsione Oraria: Finestra di input di 72 step (ore), output scalare (1).
    - Previsione Giornaliera: Finestra di input estesa (168 ore), con output dimensionato per la previsione multi-step (24 ore).

Di seguito viene riportata la rappresentazione dell'architettura CNN-BiLSTM con meccanismo di attenzione per la previsione oraria.

4.1.3 Curve di training

Prima di procedere alla validazione dei risultati finali sul test set, andiamo ad osservare le curve di addestramento che hanno guidato le scelte architetturali e parametriche dei modelli scelti. Durante l'addestramento si è notata una capacità di apprendimento superiore dei modelli più semplici nel caso orario, questi raggiungono i valori d' errore più bassi e dimostrano una rapida convergenza rispetto alle altre architetture. Al contrario, il modello basato su Attention ha evidenziato difficoltà di adattamento ai dati di training, suggerendo una complessità forse eccessiva per la natura del dataset. Gli iperparametri ottimizzati hanno di fatto portato a definire la struttura finale dei modelli prima della valutazione definitiva. L'obiettivo principale di questa sezione rimane quello di riportare i grafici dell'addestramento, andando a confrontare le funzioni di perdita nel training set con quelle nel validation set in funzione del numero di epoche.

Di seguito si riportano i grafici relativi all'andamento della funzione di perdita per le architetture applicate alla finestra di previsione oraria:

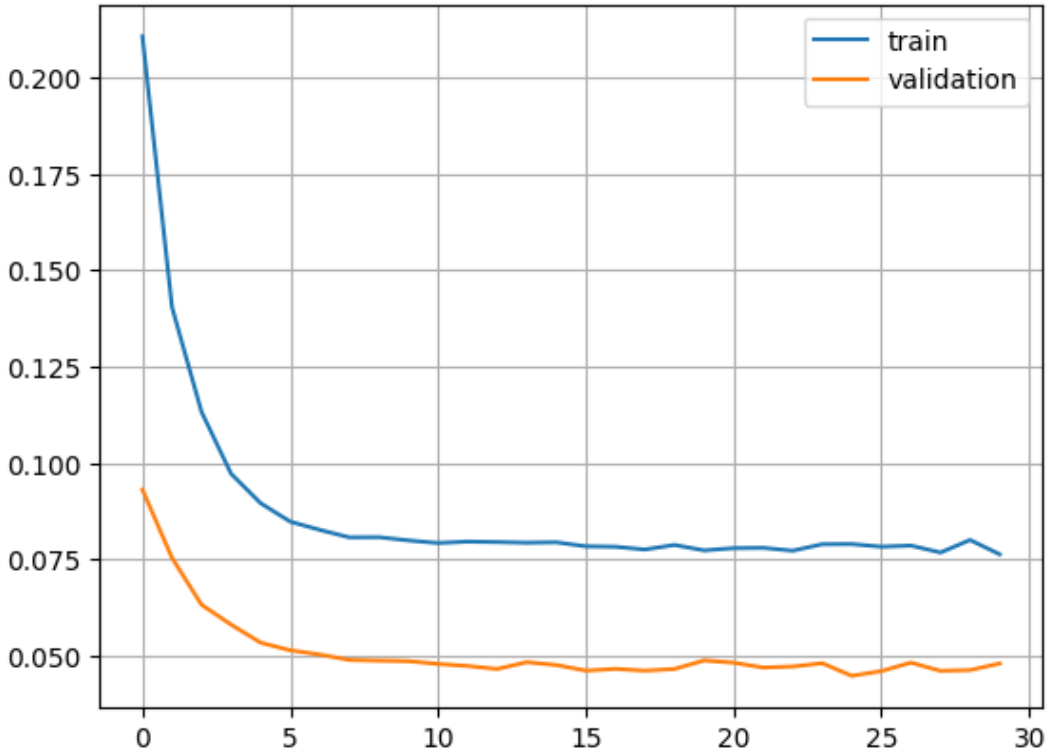

Figura 27 Andamento Loss function della LSTM oraria

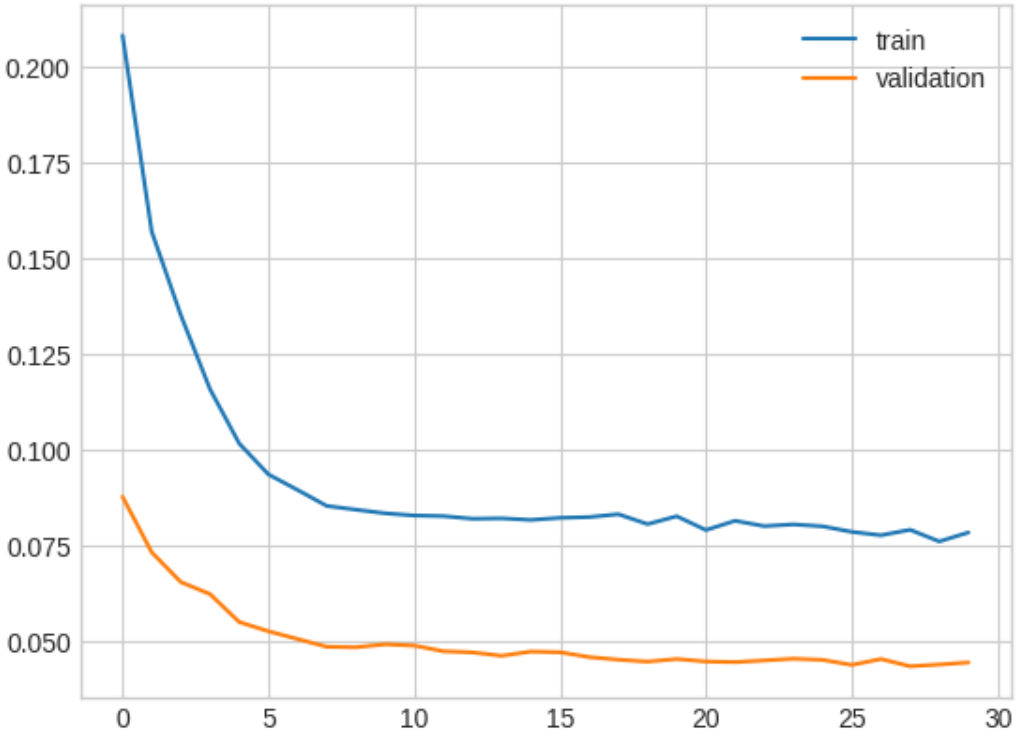

Figura 28 Andamento Loss function della LSTM oraria

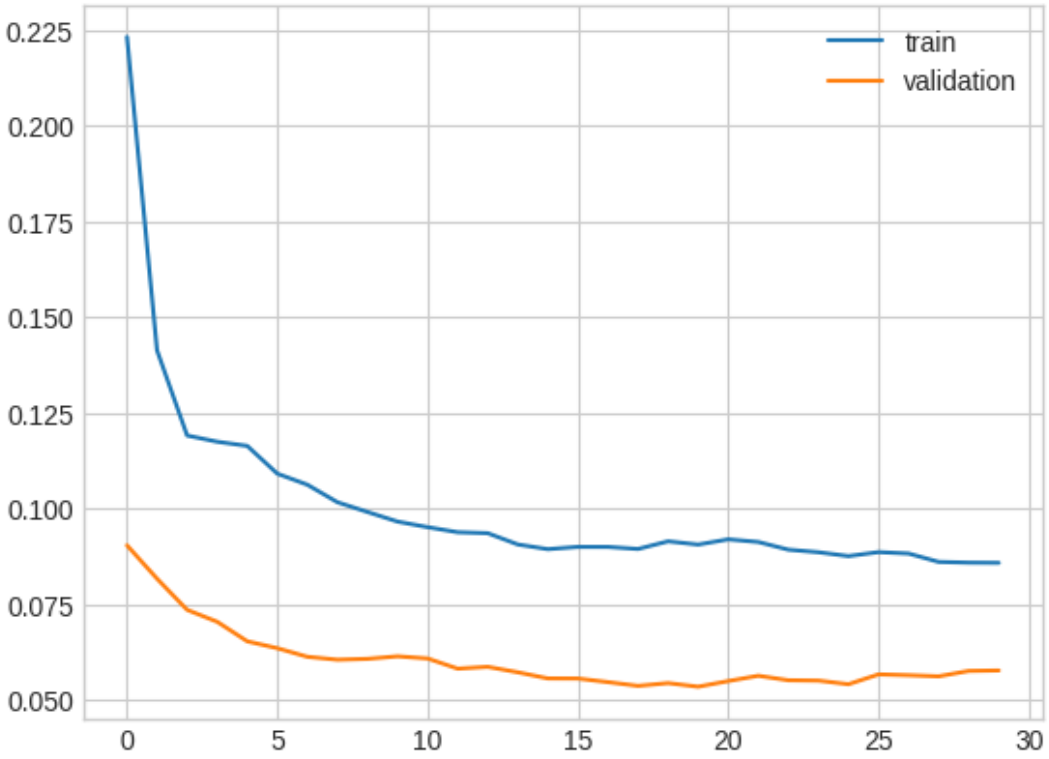

Figura 29 Andamento Loss function della CNN-LSTM oraria

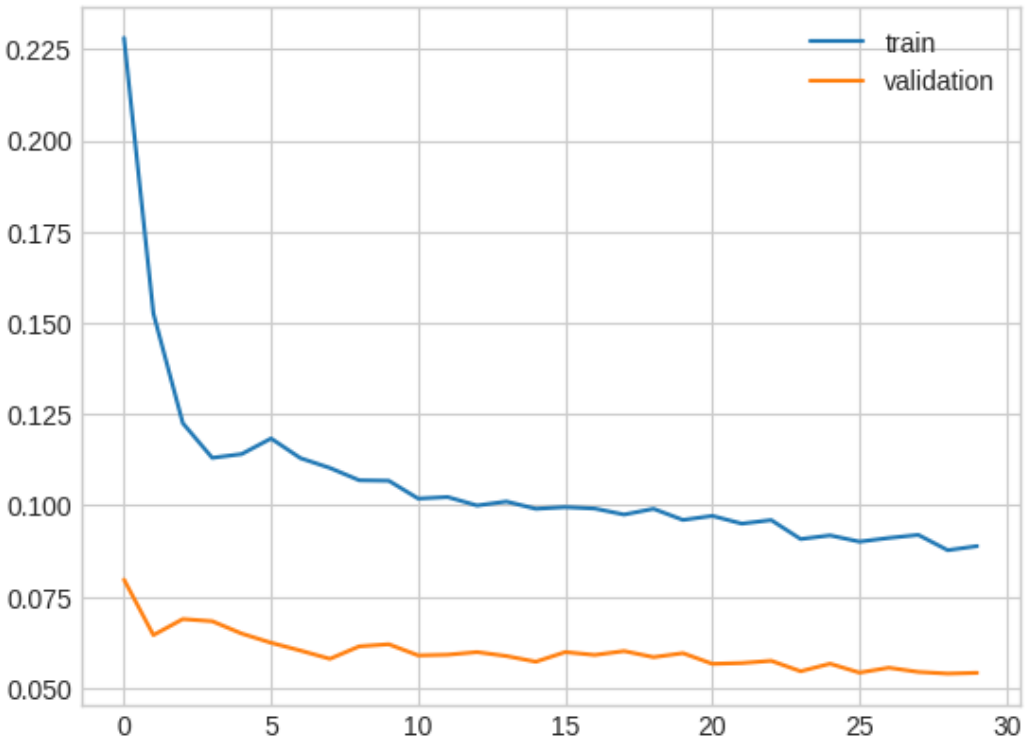

Figura 30 Andamento Loss Function della CNN-Bi LSTM oraria

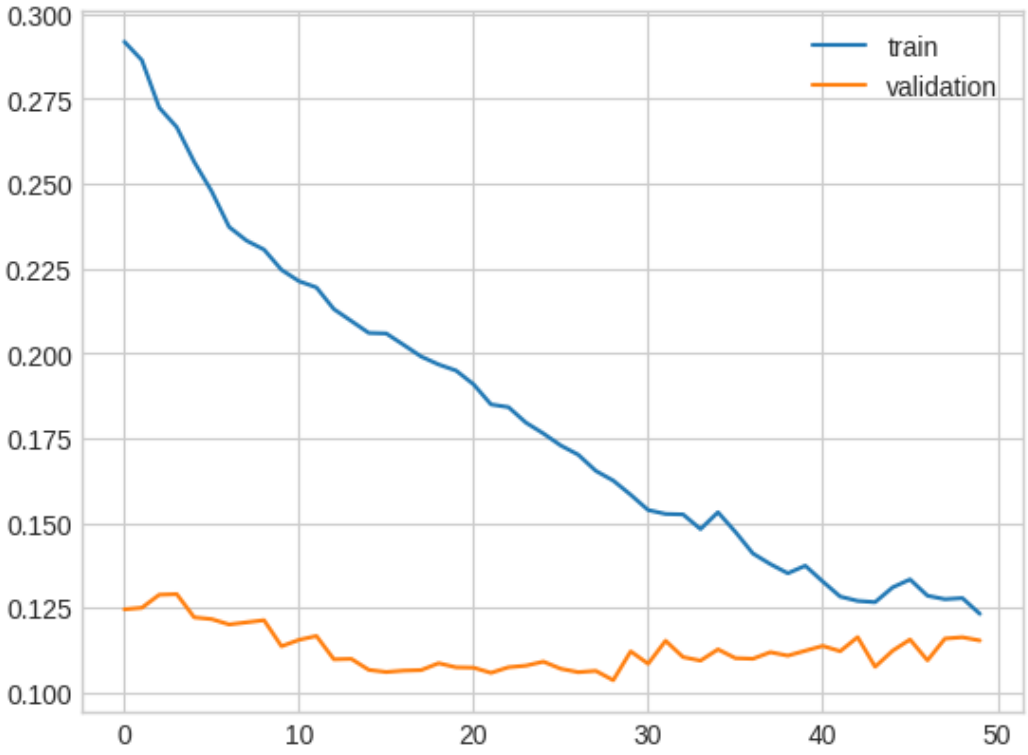

Figura 31 Andamento Loss Function della CNN-Bi LSTM con Attention oraria

Di seguito si riportano i grafici relativi all'andamento della funzione di perdita per le architetture applicate alla finestra di previsione giornaliera:

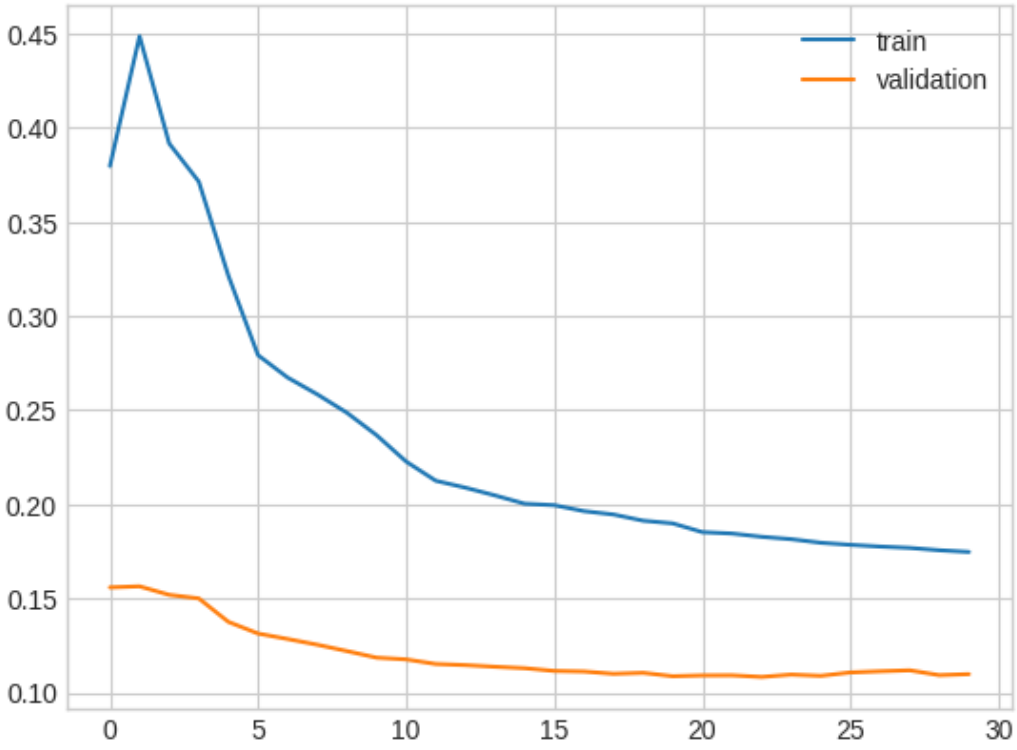

Figura 32 Andamento Loss Function della LSTM giornaliera

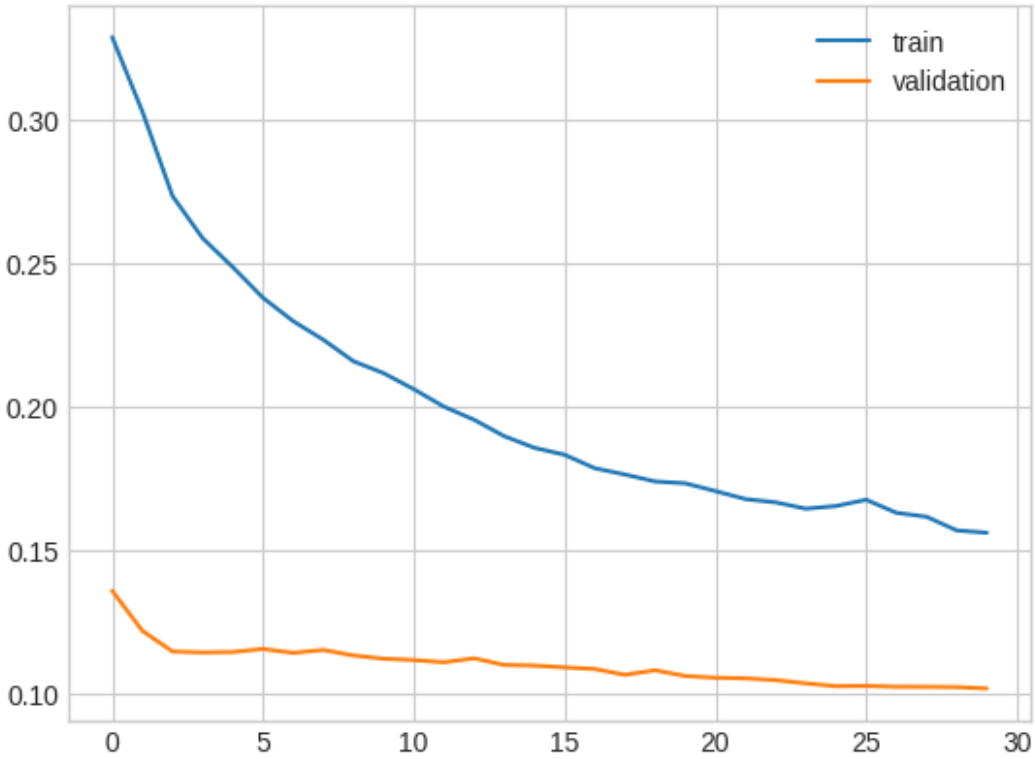

Figura 33 Andamento Loss Function della BiLSTM giornaliera

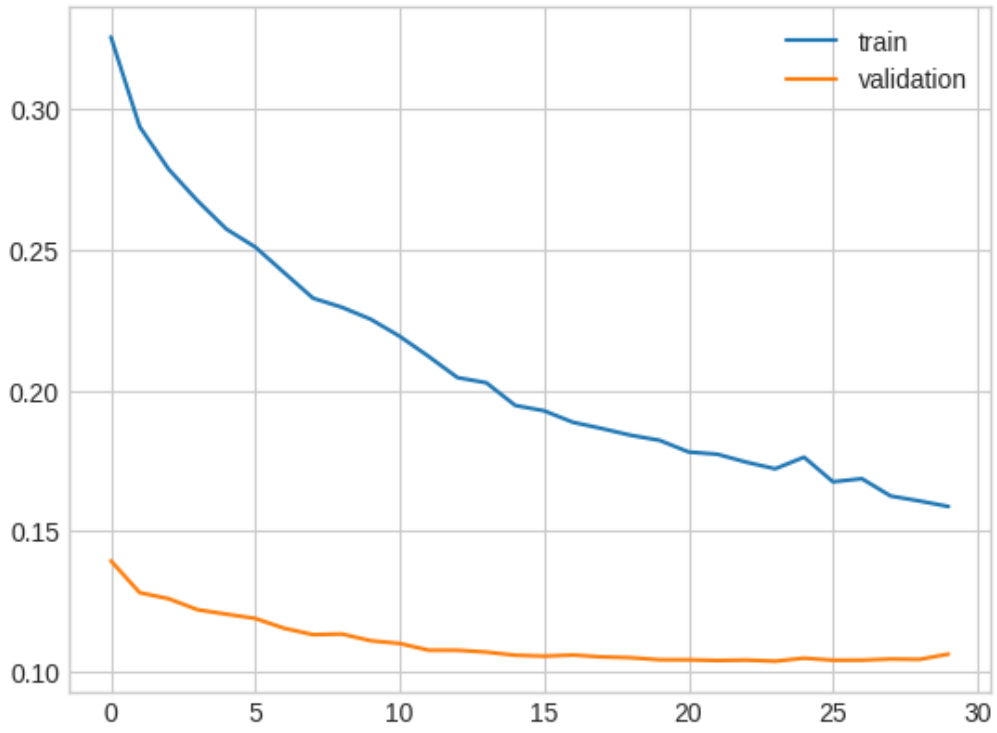

Figura 34 Andamento Loss Function della CNN-LSTM giornaliera

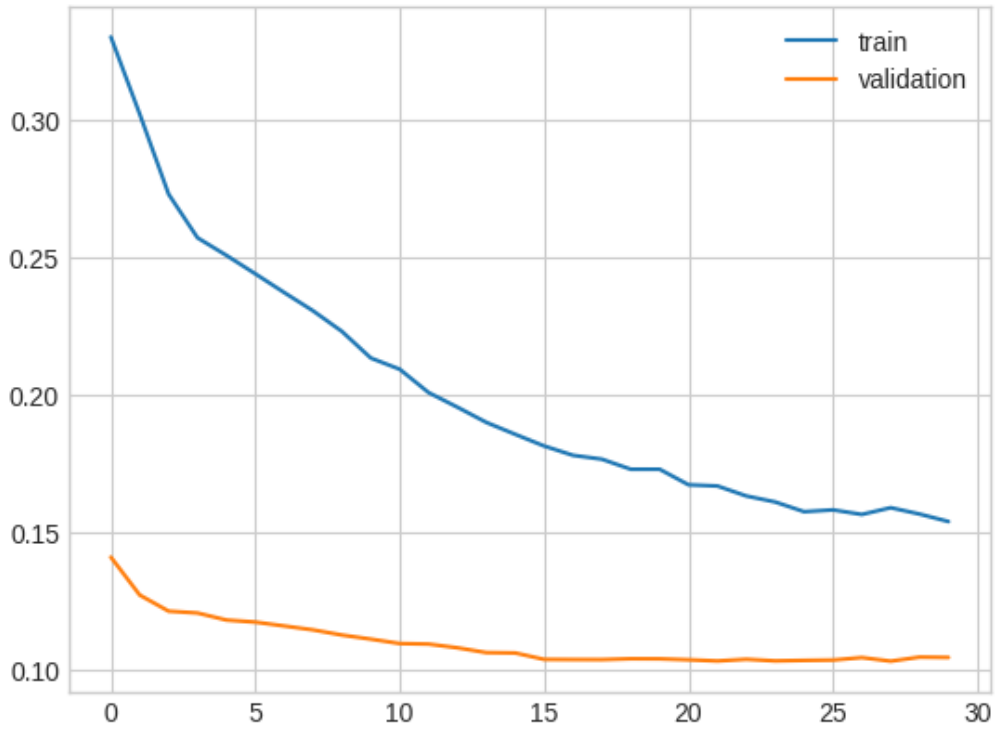

Figura 35 Andamento Loss Function della CNN-BiLSTM giornaliera

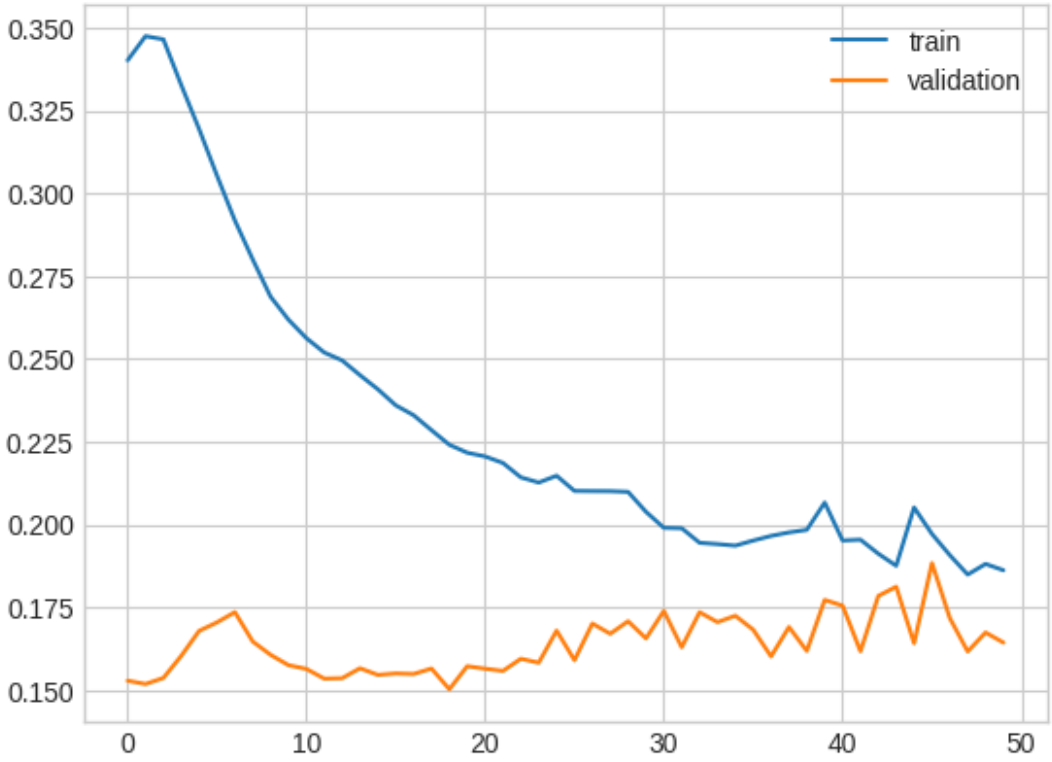

Figura 36 Andamento Loss Function CNN-BiLSTM con attention giornaliera

Figura 36

L' andamento delle due curve indica che le architetture senza meccanismo di attenzione non mostrano fenomeni di overfitting o underfitting, poiché queste si mantengono vicine tra loro suggerendo una buona capacità di generalizzazione.

Nello specifico per la finestra di previsione oraria si osserva che la curva di apprendimento sul training set appiattisce significativamente e diventa asintotica dopo circa la decima epoca, questo comportamento riflette l'abilità dei modelli di apprendere rapidamente la struttura sottostante della serie temporale, raggiungendo la convergenza in poche iterazioni. Nonostante la convergenza rapida del modello, l'addestramento è stato mantenuto per un totale di 30 epoche, per permettere alla rete di superare eventuali minimi locali

e stabilizzare i pesi poiché questo aumento di epoche ha comunque permesso una diminuzione delle metriche utilizzate per il monitoraggio.

Nelle architetture con meccanismo di attenzione la convergenza è stata decisamente più lenta e caratterizzata da overfitting ed è stato obbligatorio estendere il numero di epoche a 50,questo si traduce in un aumento del costo computazionale non giustificato da un aumento di performance rispetto ai modelli più semplici, inoltre contrariamente alla curva stabile dei modelli standard questi modelli presentano fluttuazioni marcate durante l' avanzamento dell' addestramento, questa instabilità nell' esplorazione dello spazio dei pesi indica una maggiore difficoltà nel trovare un punto di minimo.

Analizzando questi grafici appare un comportamento sistematico in cui la curva di validazione (Validation Loss) si assesta su valori inferiori rispetto alla curva di training. Questo fenomeno appare controintuitivo rispetto alla teoria classica, ma la sua spiegazione risiede nel fatto che il Training Loss riporta la media degli errori calcolati durante le epoche; dunque, mentre i pesi si stanno ancora aggiornando l'errore risulta essere particolarmente alto nei primi batch. La validation loss invece viene calcolata solo alla fine dell'epoca, quando la rete ha già beneficiato di tutti gli aggiornamenti, questo aggiunto ad un validation set più corto e stabile porta la Loss di validazione ad un valore inferiore rispetto a quella di training.

4.2 Performance sul test-set

Nel seguente paragrafo viene effettuato un confronto stagionale dei modelli scelti rispetto alle relative finestre di previsione, nello specifico vengono prima confrontati i risultati orari e poi quelli giornalieri, partendo dall' autunno del 2024 per arrivare all' estate del 2025.

4.2.1 Metriche della previsione oraria

Di seguito i risultati della previsione oraria divisi per stagioni:

AUTUNNO	MAE	RMSE	MAPE
LSTM	6.605	9.593	5.803
LSTM bi	6.707	9.601	5.959
CNN LSTM	7.388	10.428	6.666
CNN LSTM bi	7.165	10.096	5.958
CNN LSTM bi ATT	8.623	11.630	7.892

Tabella 4 Accuratezza di previsione oraria per il test set nel periodo autunnale

INVERNO	MAE	RMSE	MAPE
LSTM	5.933	8.898	6.095
LSTM bi	5.890	8.908	6.061
CNN LSTM	6.367	6.367	6.518
CNN LSTM bi	7.089	9.939	7.400
CNN LSTM bi ATT	8.028	11.326	8.441

Tabella 5 Accuratezza di previsione oraria per il test set nel periodo invernale

PRIMAVERA	MAE	RMSE	MAPE
LSTM	7.496	10.966	261.091
LSTM bi	7.773	11.438	309.635
CNN LSTM	7.925	11.086	138.799
CNN LSTM bi	7.993	11.708	274.619
CNN LSTM bi ATT	7.960	11.276	481.812

Tabella 6 Accuratezza di previsione oraria per il test set nel periodo primaverile

ESTATE	MAE	RMSE	MAPE
LSTM	5.940	8.541	6.165
LSTM bi	5.641	8.040	5.846
CNN LSTM	6.151	8.830	6.500
CNN LSTM bi	5.884	8.318	6.022
CNN LSTM bi ATT	6.081	8.914	7.236

Tabella 7 Accuratezza di previsione oraria per il test set nel periodo estivo

4.2.2 Metriche della previsione giornaliera.

Di seguito i risultati della previsione giornaliera divisi per stagioni:

AUTUNNO	MAE	RMSE	MAPE
LSTM	13.999	19.532	16.560
LSTM bi	13.629	18.545	15.645
CNN LSTM	14.411	19.884	16.024
CNN LSTM bi	12.791	18.027	15.542
CNN LSTM bi ATT	15.329	21.065	18.497

Tabella 8 Accuratezza di previsione giornaliera per il test set nel periodo autunnale

INVERNO	MAE	RMSE	MAPE
LSTM	11.387	18.249	16.418
LSTM bi	11.607	17.728	15.992
CNN LSTM	12.358	18.724	17.067
CNN LSTM bi	12.512	18.752	17.134
CNN LSTM bi ATT	13.574	19.866	17.249

Tabella 9 Accuratezza di previsione giornaliera per il test set nel periodo invernale

PRIMAVERA	MAE	RMSE	MAPE
LSTM	19.119	28.998	2119.245
LSTM bi	18.973	28.361	2119.964
CNN LSTM	17.548	27.180	2155.321
CNN LSTM bi	17.415	27.065	1999.581
CNN LSTM bi ATT	20.388	30.324	2345.105

Tabella 10 Accuratezza di previsione giornaliera per il test set nel periodo primaverile

ESTATE	MAE	RMSE	MAPE
LSTM	12.056	17.121	14.145
LSTM bi	11.213	14.950	13.134
CNN LSTM	11.515	15.408	12.356
CNN LSTM bi	10.447	14.115	11.603
CNN LSTM bi ATT	12.176	16.176	14.363

Tabella 11 Accuratezza di previsione giornaliera per il test set nel periodo estivo

In linea generale è possibile osservare che i modelli più semplici come LSTM e in particolare LSTM bidirezionale, sembrano avere performance migliori sul caso studio, mentre modelli più complessi come quelli che utilizzano il meccanismo di attenzione peggiorano gli indicatori scelti, è possibile però notare che passando dalla previsione oraria a quella giornaliera i modelli che utilizzano architetture più complesse come le CNN sembrano migliorare di molto le loro performance rispetto ai modelli che utilizzano solo le LSTM, questo accade a causa di un aumento della complessità richiesta.

4.3 Analisi grafica delle previsioni

Dopo aver misurato le performance, sì procede a un'analisi visiva dei modelli vincenti nella prima settimana predicibile del test set in questione, sovrapponendo l'andamento predetto all' andamento reale, per capire se l'inferiorità metrica del MAE si traduce in una previsione a breve termine qualitativamente migliore. Un punto metodologico cruciale è l'allineamento delle finestre di previsione tra il modello orario e quello giornaliero.

Il modello (72-in, 1-out) utilizza 72 ore di dati per generare la sua prima previsione (per l'ora 73). Il modello (168-in, 24-out) necessita di 168 ore di dati per generare la sua prima previsione (dall' ora 169 all'ora 192). Per garantire un confronto visivo equo sullo stesso identico periodo futuro, è stato necessario traslare la finestra di previsione del modello (72, 1) di 96 step (ovvero 168 - 72). In questo modo, entrambi i grafici mostrano le previsioni a partire dalla stessa ora di inizio, permettendo una sovrapposizione diretta e significativa.

4.3.1 Andamento delle previsioni orarie

Il modello orario ha un compito semplice e immediato: prevedere la prossima ora. Per tanto si caratterizza per due proprietà fondamentali:

- **Alta Reattività**: È un modello che può permettersi di essere estremamente reattivo alle condizioni più recenti.
- **Gestione dei Picchi**: Proprio per questa sua natura, è molto più abile nel catturare la volatilità a breve termine e, quindi, nel seguire da vicino anche i picchi e le valli.

Il suo svantaggio è che, pur essendo preciso, non è in grado di offrire una visione strategica.

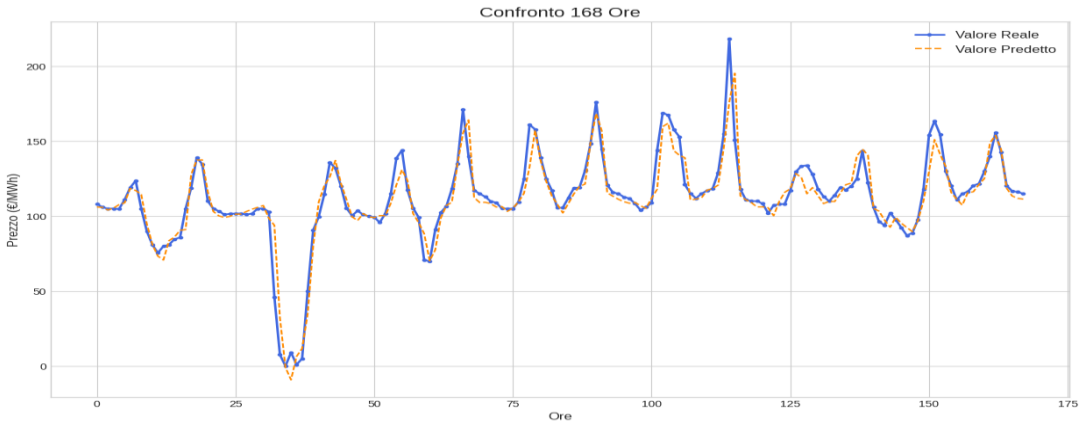

Figura 37 Confronto settimanale della previsione oraria autunnale LSTM

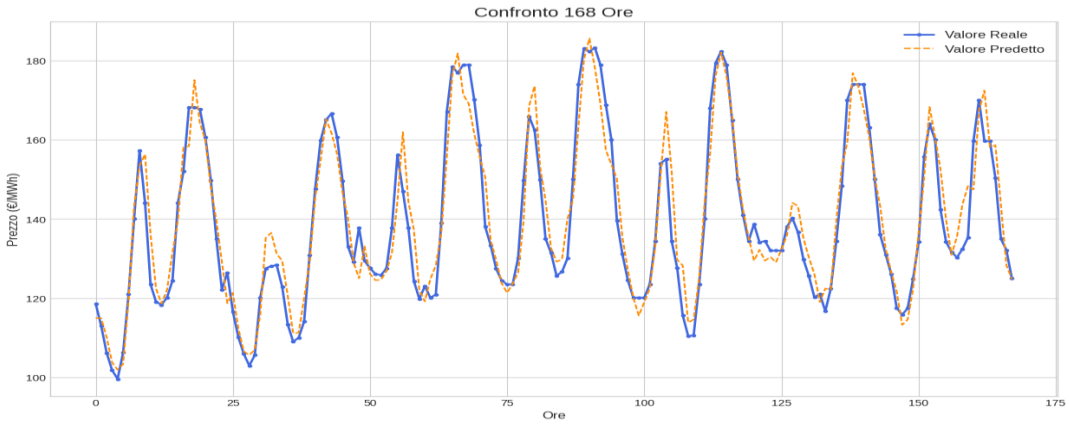

Figura 38 Confronto settimanale della previsione oraria invernale BiLSTM

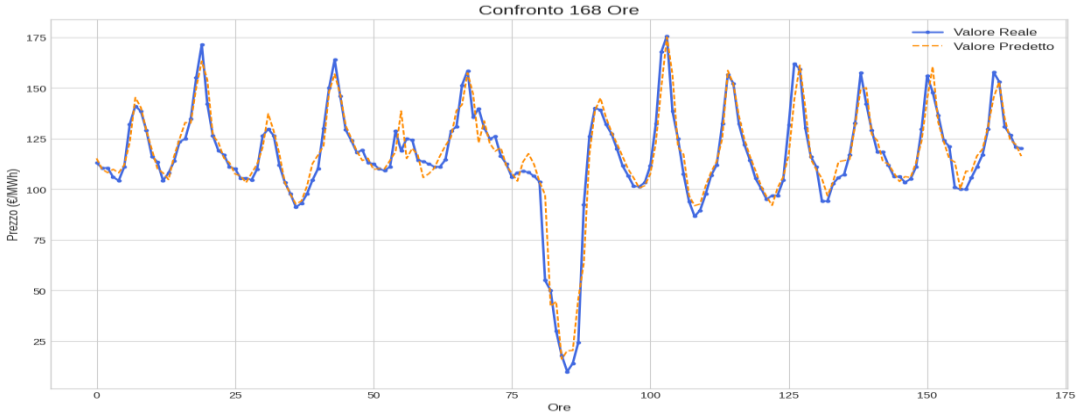

Figura 39 Confronto settimanale della previsione oraria primaverile LSTM

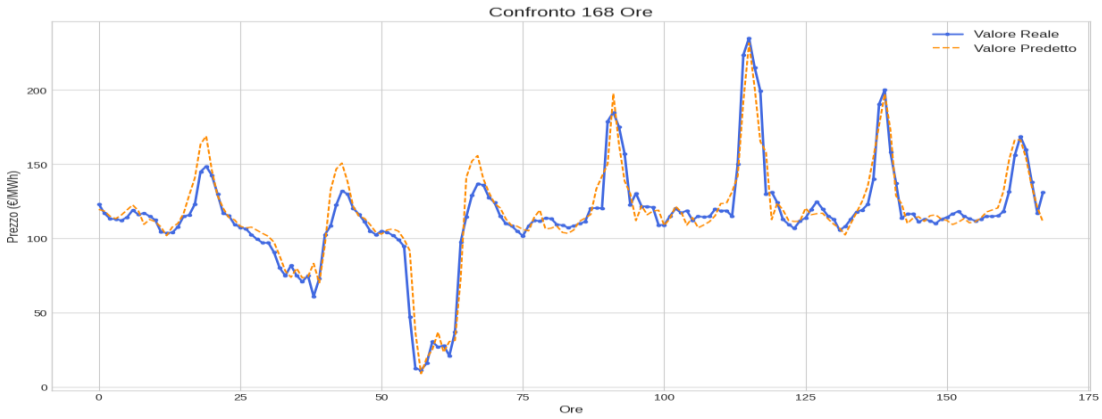

Figura 40 Confronto settimanale della previsione oraria estiva BiLSTM

4.3.2 Andamento delle previsioni giornaliere

Qui l'analisi si fa più complessa, il compito di questo modello è infatti immensamente più difficile: non deve prevedere un valore, ma ventiquattro valori futuri in un unico output. Per fare questo, il modello non può più permettersi di reagire a ogni singola fluttuazione e deve pertanto identificare il pattern sottostante associato alla fluttuazione giornaliera.

La conseguenza diretta è un fenomeno noto come appiattimento, infatti il modello tende a:

- **Puntare alla Media**: Per minimizzare l'errore su 24 ore poiché questa è la scommessa più sicura per il modello.
- **Ignorare gli Outlier**: Gli outlier come i valori molto bassi in primavera, sono per definizione deviazioni da questa media il modello pertanto , li tratta pertanto come anomalie imprevedibili, preferendo attenersi al pattern giornaliero che ha imparato.

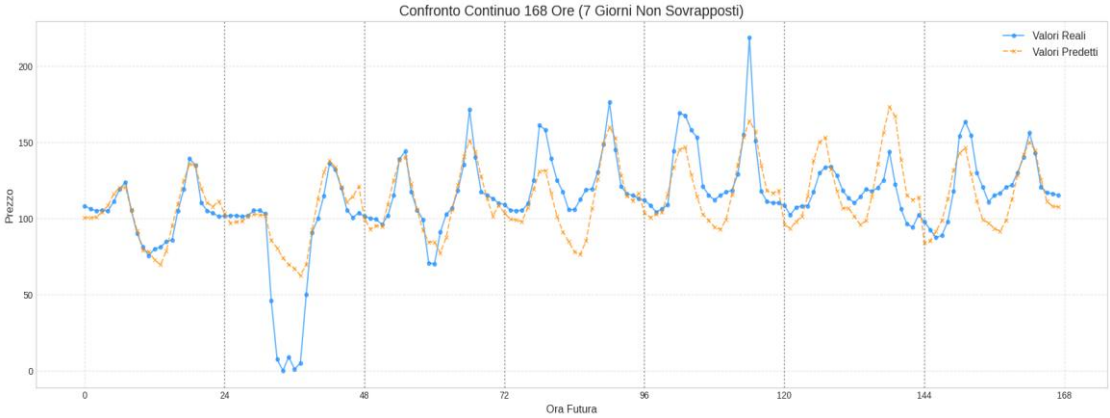

Figura 41 Confronto settimanale della previsione giornaliera autunnale CNN-BiLSTM

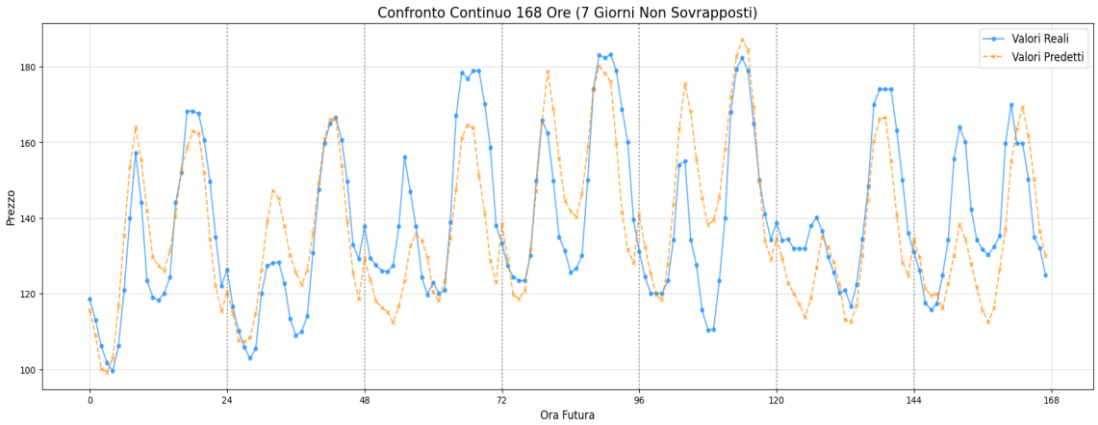

Figura 42 Confronto settimanale della previsione giornaliera invernale BiLSTM

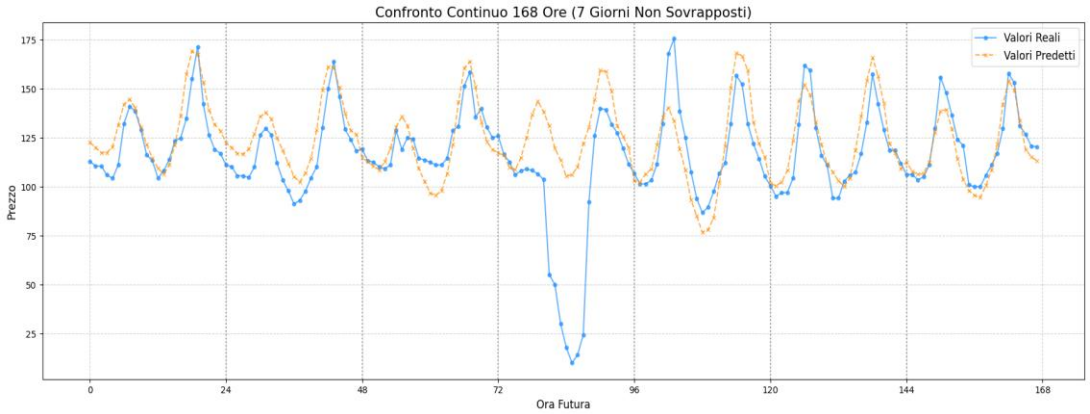

Figura 43 Confronto settimanale della previsione giornaliera primaverile CNN-BiLSTM

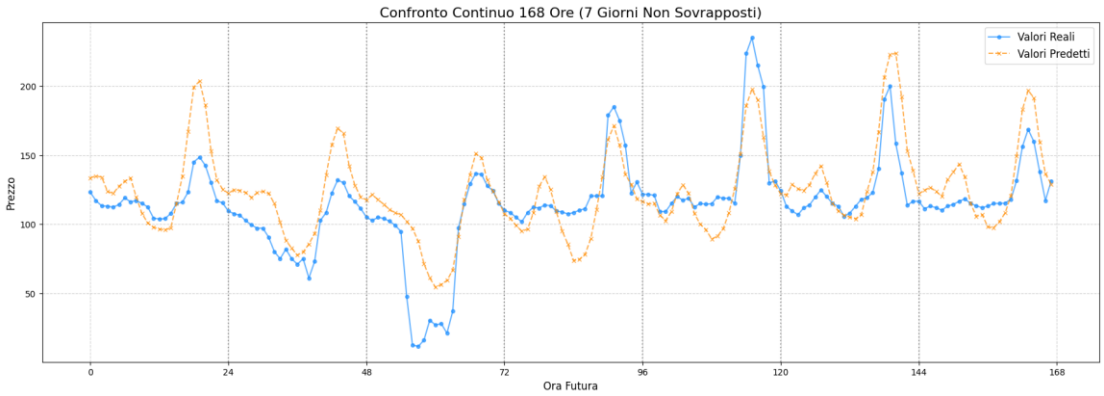

Figura 44 Confronto settimanale della previsione giornaliera estiva CNN-BiLSTM

Come possiamo osservare dai grafici riportati esistono due macro-gruppi che generano difficoltà differenti al modello in questione:

- **Autunno e primavera**: l'andamento in queste due stagioni risulta avere oscillazioni con breve ampiezza attorno alla media, ma picchi e valli significativi. In questo scenario, la strategia conservativa del modello perde di efficacia. Il modello fa un ottimo lavoro nel predire il pattern generale, ma fallisce sugli outlier, molto presenti soprattutto nel caso primaverile. La sua tendenza a puntare alla media e ignorare le deviazioni lo rende completamente cieco rispetto agli eventi critici e la sua previsione appiattita appare pessima rispetto a una realtà instabile.

- **Estate e Inverno**: Qui le oscillazioni sono molto alte ma caratterizzate ma strutturate e caratterizzate da un numero inferiore di valori anomali, in questo scenario, la strategia conservativa del modello è vincente.

Capitolo 5 – Conclusione e discussione critica dei risultati

In sintesi, l'analisi sui due orizzonti temporali non mostra un modello "buono" e uno "cattivo", ma un conflitto tra scopi; infatti, il modello orario è usato per previsioni a brevissimo termine, mentre quello giornaliero è costruito per la pianificazione strategica, ma la sua efficacia è limitata a scenari di bassa volatilità. La sua incapacità strutturale di prevedere i picchi lo rende inaffidabile proprio nei periodi più critici, dove la gestione dei picchi di prezzo è economicamente più rilevante.

Attuando un confronto empirico suddiviso per orizzonti temporali e per regimi stagionali è stato possibile valutare la robustezza dei modelli LSTM, Bi-LSTM e delle varianti ibride basate su CNN e meccanismo di Attenzione. Un'analisi approfondita dei risultati sperimentali, supportata da metriche di errore riportate nel capitolo 4, permette di formulare considerazioni che vanno oltre la semplice performance numerica.

5.1 Robustezza delle Metriche

Analizzando i dati orari della primavera 2025 in *tabella 6* si osserva una divergenza tra l'errore medio assoluto **(MAE 7.496)** e l 'errore medio percentuale **(MAPE 261.091%),** che nella *tabella 10* tocca valori elevatissimi come **(2345.105%).** Questo comportamento non è da ricercare nel fallimento dei modelli predittivi, ma nella limitazione matematica della metrica MAPE, Il problema risiede infatti nel denominatore della funzione, che per valori prossimi allo zero del prezzo reale tende a far crescere la metrica a dismisura.

Il grafico sottostante mostra l'andamento del prezzo reale nel periodo primaverile e ci mostra quanti valori di prezzo prossimi allo zero siano presenti:

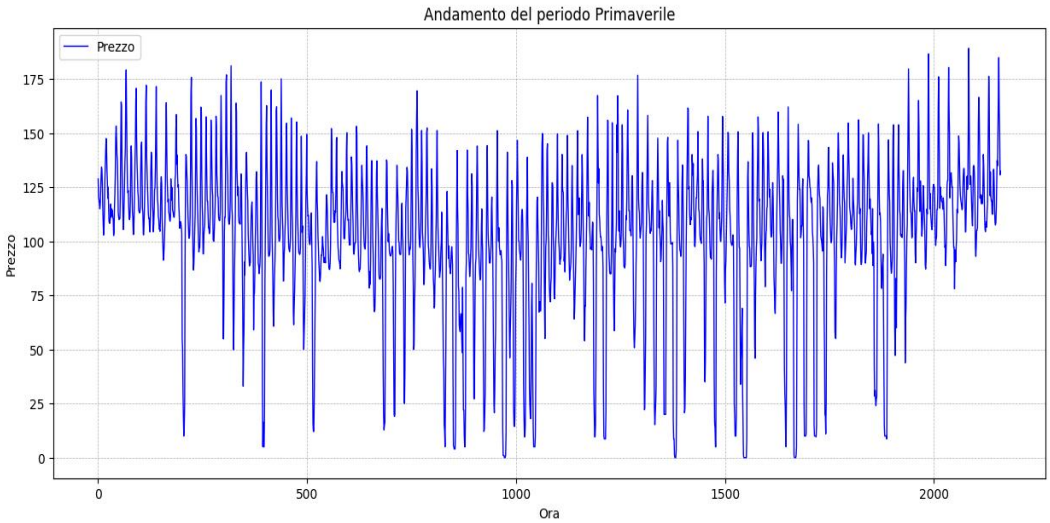

Figura 45 Andamento del prezzo orario nel periodo primaverile

Come già discusso nel capitolo 1, la crescente penetrazione delle fonti energetiche rinnovabili all' interno del mercato energetico ha reso frequente l'apparizione di prezzi marginali prossimi allo zero. In queste condizioni tale metrica perde di significato. Si conclude, in accordo con la letteratura scientifica, che la valutazione dei modelli di prezzo nel mercato elettrico debba basarsi prioritariamente su metriche assolute come MAE e RMSE, uniche garanti di una comparazione oggettiva, nello specifico per l'analisi dei modelli vincenti sono stati selezionati i modelli con valore MAE più basso.

5.2 Analisi dei modelli vincenti

In questo paragrafo vengono confrontati e analizzati i modelli rispetto all' indicatore MAE: Come era facile aspettarsi gli indicatori orari hanno valori nettamente più bassi di quelli giornalieri, questo è logico, poiché prevedere un singolo punto nel tempo è più semplice che prevedere un valore aggregato, inaspettatamente invece i modelli hanno catturato bene le variazioni di prezzo estive e invernali, al pari di quelle autunnali, che sono notoriamente più facili da prevedere, al contrario i mesi primaverili sembrano essere particolarmente difficili da prevedere, probabilmente a causa della loro instabilità meteorologica che influenza la generazione da rinnovabili, nella tabella riassuntiva sottostante, vengono riportati i modelli che hanno ottenuto valori di MAE inferiori:

	ORARIO	GIORNALIERO
AUTUNNO	**LSTM (**6.605)	**CNN LSTM bi (**12.791)
INVERNO	**LSTM bi** (5.890)	**LSTM bi** (11.607)
PRIMAVERA	**LSTM** (7.496)	**CNN LSTM bi (**17.415)
ESTATE	**LSTM bi** (5.641)	**CNN LSTM bi** (10.447)

Tabella 12 Risultati delle Architetture che minimizzano il MAE

5.3 Efficacia Architetturale

Come evidenziato non esista un'architettura universalmente ottima, infatti la performance è strettamente legata al compito di previsione:

- **Analisi della previsione oraria:** I risultati sperimentali ottenuti in *Tabella 11* premiano le architetture ricorrenti pure. In particolare, nel dataset invernale, il modello **Bi-LSTM** ha ottenuto il miglior risultato assoluto con un **MAE di 5.890**, superando nettamente i modelli ibridi più complessi come *CNN-LSTM bi* **(MAE 7.089)** e quelli dotati di meccanismo di attenzione **(MAE 10.169)**. Questo risultato si allinea con quanto osservato nella letteratura recente sulla gestione delle dipendenze temporali. Nel brevissimo termine, la serie storica dei prezzi mostra una forte autocorrelazione. L'architettura Bi-LSTM, grazie alla sua capacità di processare l'informazione in entrambe le direzioni temporali, riesce a catturare efficacemente questa dipendenza sequenziale. L'introduzione di strati convoluzionali (CNN) in questo contesto sembra introdurre una complessità non necessaria, che agisce come rumore strutturale aumentando l' overfitting sui dati di testing.

- **Analisi dell'Orizzonte Giornaliero:** In questo caso lo scenario si inverte drasticamente, l'obiettivo si sposta sulla previsione dell'intero vettore giornaliero e le architetture che aumentano maggiormente le performance sono quelle che utilizzano le reti neurali convoluzionali CNN.

Per esempio, nella stagione autunnale, l'architettura ibrida **CNN-BI-LSTM (MAE 12.791)** sovraperforma la semplice **Bi-LSTM (MAE 13.629).**

Queste serie storiche sono caratterizzate da alta non-linearità e volatilità, quando l'orizzonte temporale si allunga, la sola memoria ricorrente (LSTM) fatica a mantenere la coerenza globale della previsione ed è qui che l'integrazione della CNN diventa cruciale: i filtri convoluzionali non lavorano sul tempo, ma sullo spazio dei dati, estraendo feature latenti e pattern locali significativi dalla sequenza di input prima che questi vengano processati dalla rete principale. La CNN funge quindi da estrattore di caratteristiche di alto

livello, passando il segnale alla LSTM e permettendole di modellare meglio la struttura del prezzo.

Un dato che emerge in entrambi gli orizzonti temporali e in tutte le stagioni è la sistematica inefficacia del meccanismo di attenzione, che ha prodotto nella totalità degli esperimenti il risultato peggiore. Nello scenario primaverile ad esempio, il modello **CNN LSTM bi ATT** registra il **MAE** più alto in assoluto **(20.388)** rispetto al miglior modello **CNN LSTM (17.415)**. A seguito di queste osservazioni possiamo evidenziare due possibili cause:

- **Overfitting:** L'aggiunta del meccanismo di attenzione aumenta la complessità, per tanto il modello tende a memorizzare il rumore piuttosto che apprendere le relazioni causali, perdendo capacità di generalizzazione sul test set.

- **Dispersione del Segnale:** Il meccanismo di attenzione assegna pesi di importanza a tutti gli step temporali passati, ma nel caso specifico l'informazione più rilevante è spesso contenuta nelle osservazioni immediatamente precedenti. L'Attenzione, cercando correlazioni anche in un passato lontano, che potrebbe non essere rilevante a causa della rapida evoluzione del mercato, finisce per dissipare il segnale forte degli istanti recenti introducendo distorsioni nella previsione finale.

5.4 Differenze stagionali e impatto delle variabili esogene

Analizzando questi risultati appare evidente una disparità di performance, i dati mostrano una differenza sostanziale tra le stagioni climaticamente più definite e tra i periodi di transizione, quello primaverile particolarmente.

- **Performance nelle Stagioni Stabili:** Contrariamente alle aspettative sulla volatilità dei consumi del capitolo 3, i modelli hanno mostrato

un'eccellente capacità di adattamento durante l'Estate 2025 e l'Inverno 2024/2025**.** In questi periodi, le architetture hanno registrato i risultati migliori: nella previsione oraria estiva, il modello **Bi-LSTM** ha raggiunto (MAE 5.641) mantenendosi su livelli molto bassi anche in inverno con un (MAE di 5.890). Questi dati indicano che, in presenza di pattern di consumo definiti e strutturati, le architetture dominanti riconoscono efficacemente la ciclicità del prezzo utilizzando esclusivamente lo storico temporale.

- **La Criticità della Primavera:** La Primavera 2025 rappresenta invece il punto di rottura per le performance del modello. In questa stagione si osserva un degrado sistematico della precisione per tutte le architetture, con un MAE orario che aumenta drasticamente **LSTM** (7.496) e un errore giornaliero che arriva quasi a raddoppiare rispetto all' estate **CNN LSTM bi (**17.415). L'analisi visiva dei dati reali conferma la presenza di frequenti outlier e valori prossimi allo zero, tipici di questo periodo.

L' autunno invece nonostante abbia alcune criticità previsionali è, in termini di performance metriche (Oraria 6.605 e Giornaliera 12.791**),** più assimilabile alle stagioni stabili, piuttosto che a quella primaverili, probabilmente a causa della migliore stabilità metereologica rispetto alla primavera.

Infatti l' instabilità metereologica dei mesi primaverili influenza in modo massiccio la generazione da fonti rinnovabili, shock di offerta improvvisi disaccoppiano il prezzo dai suoi pattern storici abituali, essendo i modelli proposti in questa tesi condizionati solo da variabili di natura endogena come il prezzo, il volume di acquisto e l' offerta e non includendo quindi variabili esogene come previsioni meteo, velocità del vento o irraggiamento, essi mancano del contesto informativo necessario per distinguere una normale fluttuazione di mercato da un cambio strutturale indotto dal meteo. Di conseguenza, il modello tende ad appiattirsi sulla media stagionale, fallendo nel prevedere i picchi di volatilità e i crolli di prezzo dettati da fattori esterni alla serie storica stessa.

5.5 Prospettive Future

Alla luce dei risultati ottenuti e delle limitazioni discusse, la ricerca futura si dovrebbe orientare su due direttrici principali, ispirate alle metodologie avanzate di decomposizione del segnale:

- **Integrazione di variabili esogene:** Per risolvere la scarsa performance primaverile, è necessario evolvere l'architettura verso un input che inglobi previsioni meteorologiche, permettendo al modello di apprendere le relazioni causali tra meteo e prezzo, e non solo quelle statistiche temporali.

- **Integrazione di Tecniche di Decomposizione (VMD/CEEMDAN):** Come evidenziato nel paper di Zhu et al.[13], le serie energetiche sono altamente volatili. L'applicazione preliminare di tecniche di decomposizione come la **Variational Mode Decomposition (VMD)** permetterebbe di separare il segnale originale in **sottomodi (IMF)** a diverse frequenze, semplificando il compito di apprendimento della rete neurale e isolando il rumore ad alta frequenza dal trend principale.

Riferimenti Normativi e Regolatori

[3] Decreto Legislativo 16 marzo 1999, n. 79, *"Attuazione della direttiva 96/92/CE recante norme comuni per il mercato interno dell'energia elettrica"* (testo coordinato aggiornato al 05.08.2022). Disponibile su: dgdighe.mit.gov.it. Ultima consultazione: 23/10/2025.

[4] ARERA, Deliberazione 23 luglio 2024, 304/2024/R/eel, *"Superamento del prezzo unico nazionale e modifiche al Testo integrato del dispacciamento elettrico (TIDE) funzionali alla sua entrata in operatività al 1° gennaio 2025"*. Disponibile su: www.arera.it. Ultima consultazione: 23/10/2025.

SITOGRAFIA

[1] Terna S.p.A., "Transparency Report - Dati Generazione e Fabbisogno," [Online]. Disponibile: https://www.terna.it.

[2] Gestore dei Mercati Energetici (GME), "Vademecum della Borsa Elettrica," [Online]. Disponibile: https://www.mercatoelettrico.org.

[27] Gestore dei Mercati Energetici (GME), "Dati storici del Mercato del Giorno Prima (MGP)," [Online].
Disponibile: https://www.mercatoelettrico.org.

BIBLIOGRAFIA

[5] X. Lu, J. Qiu, G. Lei, et al., "Scenarios modelling for forecasting day-ahead electricity prices: case studies in Australia," *Appl. Energy*, vol. 308, p. 118296, 2022. DOI: 10.1016/j.apenergy.2021.118296

[6] M.S. Al-Musaylh, R.C. Deo, Y. Li, "Two-phase particle swarm optimized-support vector regression hybrid model integrated with improved empirical mode decomposition with adaptive noise for multiple-horizon electricity demand forecasting," *Appl. Energy*, vol. 217, pp. 422–439, 2018. DOI: 10.1016/j.apenergy.2018.02.140

[7] J. Zhao, Z. Dong, X. Li, et al., "A framework for electricity price spike analysis with advanced data mining methods," *IEEE Trans. Power Syst.*, vol. 22, pp. 376–385, 2007. DOI: 10.1109/TPWRS.2006.889139

[8] N. Ludwig, S. Feuerriegel, D. Neumann, "Putting Big Data analytics to work: feature selection for forecasting electricity prices using the LASSO and random forests," *J. Decis. Syst.*, vol. 24, pp. 19–36, 2015. DOI:10.1080/12460125.2015.994290

[9] X. Chen, Z. Dong, K. Meng, et al., "Electricity price forecasting with extreme learning machine and bootstrapping," *IEEE Trans. Power Syst.*, vol. 27, pp. 2055–2062, 2012. DOI: 10.1109/TPWRS.2012.2190627

[10] P. Jiang, Y. Nie, J. Wang, et al., "Multivariable short-term electricity price forecasting using artificial intelligence and multi-input multi-output scheme," *Energy Econ.*, vol. 117, p. 106471, 2023. DOI: 10.1016/j.eneco.2022.106471

[11] J. Lago, F. De Ridder, B. De Schutter, "Forecasting spot electricity prices: deep learning approaches and empirical comparison of traditional algorithms," *Appl. Energy*, vol. 221, pp. 386–405, 2018. DOI:10.1016/j.apenergy.2018.02.069

[12] F. A. Gers, D. Eck, and J. Schmidhuber, "Applying LSTM to time series predictable through time-window approaches," in *Proc. Int. Conf. Artif. Neural Netw. (ICANN)*, 2001, pp. 669–676. DOI: 10.1007/3-540-44668-0_93

[13] Z. Wang, B. Xu, Y. Huang, et al., "Short Term Electricity Price Prediction using CNN-BiLSTM Based on Attention Mechanism," in *2024 4th International Conference on Energy Engineering and Power Systems (EEPS), 2024. DOI:10.1109/EEPS63402.2024.10804553*

[14] G. Memarzadeh, F. Keynia, "Short-term electricity load and price forecasting by a new optimal LSTM-NN based prediction algorithm," *Elec. Power Syst. Res.*, vol. 192, p. 106995, 2021. DOI: 10.1016/j.epsr.2020.106995

[15] S. Deng, J. Inekwe, V. Smirnov, et al., "Seasonality in deep learning forecasts of electricity imbalance prices," *Energy Econ.*, vol. 137, p. 107770, 2024. DOI: 10.1016/j.eneco.2024.107770

[16] Y. Xu, X. Huang, X. Zheng, Z. Zeng, and T. Jin, "VMD-ATT-LSTM electricity price prediction based on grey wolf optimization algorithm in electricity markets considering renewable energy," *Renewable Energy*, vol. 236, p. 121408, 2024. DOI: 10.1016/j.renene.2024.121408

[17] A. Alhendi, A. S. Al-Sumaiti, M. Marzband, R. Kumar, and A. A. Z. Diab, "Short-term load and price forecasting using artificial neural network with enhanced Markov chain for ISO New England," *Energy Reports*, vol. 9, pp. 4799-4815, 2023. DOI: 10.1016/j.egyr.2023.03.116

[18] T. M. Mitchell, *Machine Learning*. New York, NY, USA: McGraw-Hill, 1997. ISBN: 978-0070428072

[19] F. Rosenblatt, "The perceptron: A probabilistic model for information storage and organization in the brain," *Psychological Review*, vol. 65, n. 6, pp. 386–408, 1958.

[20] D. E. Rumelhart, G. E. Hinton, e R. J. Williams, "Learning representations by back-propagating errors," *Nature*, vol. 323, n. 6088, pp. 533–536, 1986. DOI: 10.1038/323533a0.

[21] J. L. Elman, "Finding structure in time," *Cognitive Science*, vol. 14, n. 2, pp. 179–211, 1990. DOI: 10.1207/s15516709cog1402_1.

[22] Y. Bengio, P. Simard, e P. Frasconi, "Learning long-term dependencies with gradient descent is difficult," *IEEE Transactions on Neural Networks*, vol. 5, n. 2, pp. 157–166, 1994. DOI: 10.1109/72.279181.

[23] S. Hochreiter e J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, n. 8, pp. 1735-1780, 1997. DOI: 10.1162/neco.1997.9.8.1735.

[24] M. Schuster e K. K. Paliwal, "Bidirectional recurrent neural networks," *IEEE Transactions on Signal Processing*, vol. 45, n. 11, pp. 2673-2681, 1997. DOI: 10.1109/78.650093.
[25] Y. LeCun, L. Bottou, Y. Bengio, e P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, n. 11, pp. 2278-2324, 1998. DOI: 10.1109/5.726791.
[26] Y. Qin, D. Song, H. Chen, W. Cheng, G. Jiang, e G. Cottrell, "A Dual-Stage Attention-Based Recurrent Neural Network for Time Series Prediction," in *Proceedings of the 26th International Joint Conference on Artificial Intelligence* (IJCAI), 2017, pp. 2627–2633. DOI: 10.24963/ijcai.2017/366.
[28] L. Hirth, "The market value of variable renewables: The effect of solar and wind power curtailment on their maximum share in the power grid," *Energy Economics*, vol. 38, 2013, pp. 218–236. DOI: 10.1016/j.eneco.2013.02.004.